Big Data

BUT Science des Données - Metz

Berhocoïrigoin Elena

Objectifs (20h)

- Big Data : origine, définition, domaines d'application
- Concepts autour des Big Data
- Solutions dédiées :
  - MapReduce
  - Spark

Chapitre 1. L'ère du Big Data

Chapitre 2. Big Data : Qu'est-ce-que c'est ?

Chapitre 3. Big Data : Pour quoi faire ?

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

Nous sommes tous à la fois des producteurs et des consommateurs de données - Exemple

Nous générons des données …

… et nous consommons des données

Instagram

Nous sommes tous à la fois des producteurs et des consommateurs de données - Exemple

Nous générons des données ...

... et nous consommons des données

Production active

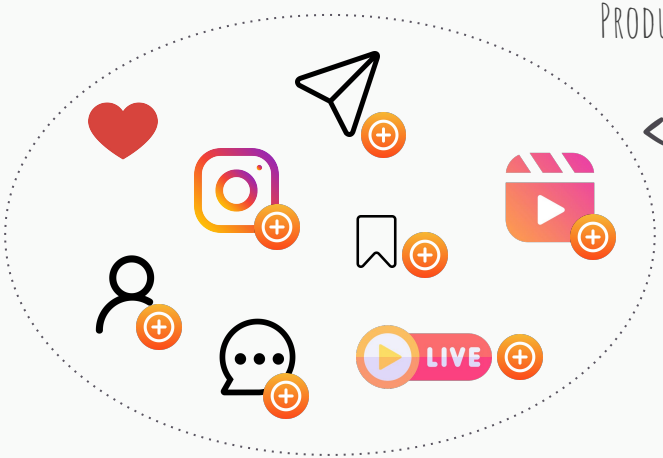

Instagram

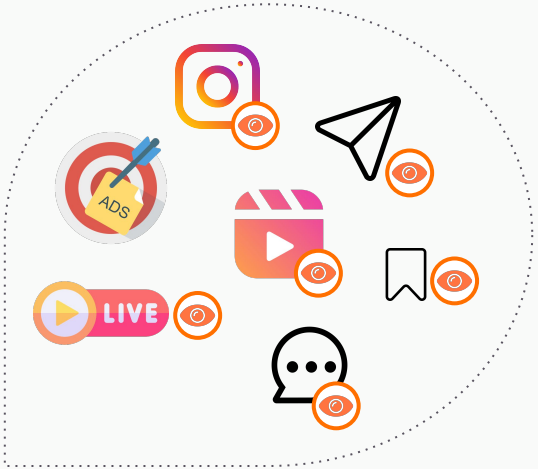

Production passive

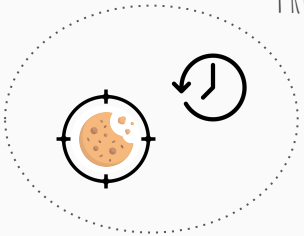

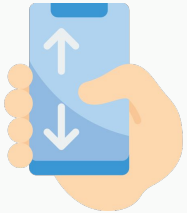

Le mode de production et de consommation des données a profondément changé - Exemples

Domaine	Centralisé	Décentralisé
Médias	**Production** : journaux, télévision, radio **Consommation passive** : lire, écouter, regarder	**Production / Consommation primaire** : réseaux sociaux (vidéos, tweets, infographies, lives etc. d'information ...), blogs, podcasts ... **Consommation / Production secondaire** : commentaires, like, partage, react vidéo ou live ...
Cartographie		
Commerce		
Mobilité		
Santé		
Science		

Le mode de production et de consommation des données a profondément changé - Exemples

Domaine	Centralisé	Décentralisé
Médias	**Production** : journaux, télévision, radio **Consommation passive** : lire, écouter, regarder	**Production / Consommation primaire** : réseaux sociaux (vidéos, tweets, infographies, lives etc. d'information ...), blogs, podcasts ... **Consommation / Production secondaire** : commentaires, like, partage, react vidéo ou live ...
Cartographie	**Production** : • institutions publiques (ex : cartes IGN), • entreprises (ex : carte Google Maps) ... **Consommation passive** : se localiser à partir des informations données	**Production / Consommation primaire** : outils collaboratifs (ex : carte OpenStreetMap, cartographie Waze) **Consommation / Production secondaire** : avis, notes, commentaires sur Google Maps
Commerce		
Mobilité		
Santé		
Science		

Le mode de production et de consommation des données a profondément changé - Exemples

Domaine	Centralisé	Décentralisé
Médias	**Production** : journaux, télévision, radio **Consommation passive** : lire, écouter, regarder	**Production / Consommation primaire** : réseaux sociaux (vidéos, tweets, infographies, lives etc. d'information ...), blogs, podcasts ... **Consommation / Production secondaire** : commentaires, like, partage, react vidéo ou live ...
Cartographie	**Production** : ● institutions publiques (ex : cartes IGN), ● entreprises (ex : carte Google Maps) ... **Consommation passive** : se localiser à partir des informations données	**Production / Consommation primaire** : outils collaboratifs (ex : carte OpenStreetMap, cartographie Waze) **Consommation / Production secondaire** : avis, notes, commentaires sur Google Maps
Commerce	**Production** : entreprises (catalogue produits, publicités, sondages ...)	**Production / Consommation primaire** : cookies (traces numériques) **Consommation / Production secondaire** : avis, notes, commentaires
Mobilité		
Santé		
Science		

Le mode de production et de consommation des données a profondément changé - Exemples

Domaine	Centralisé	Décentralisé
Médias	**Production** : journaux, télévision, radio **Consommation passive** : lire, écouter, regarder	**Production / Consommation primaire** : réseaux sociaux (vidéos, tweets, infographies, lives etc. d'information ...), blogs, podcasts ... **Consommation / Production secondaire** : commentaires, like, partage, react vidéo ou live ...
Cartographie	**Production** : ● institutions publiques (ex : cartes IGN), ● entreprises (ex : carte Google Maps) ... **Consommation passive** : se localiser à partir des informations données	**Production / Consommation primaire** : outils collaboratifs (ex : carte OpenStreetMap, cartographie Waze) **Consommation / Production secondaire** : avis, notes, commentaires sur Google Maps
Commerce	**Production** : entreprises (catalogue produits, publicités, sondages ...)	**Production / Consommation primaire** : cookies (traces numériques) **Consommation / Production secondaire** : avis, notes, commentaires
Mobilité	**Production** : institutions publiques (données de transport officielles telles ques les horaires des bus, les plans du réseau ...)	**Production / Consommation primaire** : outils collaboratifs (cartographie Waze, trajets partagés BlaBlaCar ...)
Santé		
Science		

Le mode de production et de consommation des données a profondément changé - Exemples

Domaine	Centralisé	Décentralisé
Médias	**Production** : journaux, télévision, radio **Consommation passive** : lire, écouter, regarder	**Production / Consommation primaire** : réseaux sociaux (vidéos, tweets, infographies, lives etc. d'information …), blogs, podcasts … **Consommation / Production secondaire** : commentaires, like, partage, react vidéo ou live …
Cartographie	**Production** : ● institutions publiques (ex : cartes IGN), ● entreprises (ex : carte Google Maps) … **Consommation passive** : se localiser à partir des informations données	**Production / Consommation primaire** : outils collaboratifs (ex : carte OpenStreetMap, cartographie Waze) **Consommation / Production secondaire** : avis, notes, commentaires sur Google Maps
Commerce	**Production** : entreprises (catalogue produits, publicités, sondages …)	**Production / Consommation primaire** : cookies (traces numériques) **Consommation / Production secondaire** : avis, notes, commentaires
Mobilité	**Production** : institutions publiques (données de transport officielles telles ques les horaires des bus, les plans du réseau …)	**Production / Consommation primaire** : outils collaboratifs (cartographie Waze, trajets partagés BlaBlaCar …)
Santé	**Production** : institutions publiques (dossier médical, examens médicaux …)	**Production / Consommation** : ● montres connectées (rythme cardiaque, détection des chutes …) ● capteur de glycémie pour les diabétiques ● forums (discussions) ● réseaux sociaux (vidéos, infographie etc de sensibilisation et de vulgarisation …) **Consommation / Production secondaire** : recherches internet, avis sur les praticiens
Science		

Le mode de production et de consommation des données a profondément changé - Exemples

Domaine	Centralisé	Décentralisé
Médias	**Production** : journaux, télévision, radio **Consommation passive** : lire, écouter, regarder	**Production / Consommation primaire** : réseaux sociaux (vidéos, tweets, infographies, lives etc. d'information …), blogs, podcasts … **Consommation / Production secondaire** : commentaires, like, partage, react vidéo ou live …
Cartographie	**Production** : ● institutions publiques (ex : cartes IGN), ● entreprises (ex : carte Google Maps) … **Consommation passive** : se localiser à partir des informations données	**Production / Consommation primaire** : outils collaboratifs (ex : carte OpenStreetMap, cartographie Waze) **Consommation / Production secondaire** : avis, notes, commentaires sur Google Maps
Commerce	**Production** : entreprises (catalogue produits, publicités, sondages …)	**Production / Consommation primaire** : cookies (traces numériques) **Consommation / Production secondaire** : avis, notes, commentaires
Mobilité	**Production** : institutions publiques (données de transport officielles telles ques les horaires des bus, les plans du réseau …)	**Production / Consommation primaire** : outils collaboratifs (cartographie Waze, trajets partagés BlaBlaCar …)
Santé	**Production** : institutions publiques (dossier médical, examens médicaux …)	**Production / Consommation** : ● montres connectées (rythme cardiaque, détection des chutes …) ● capteur de glycémie pour les diabétiques ● forums (discussions) ● réseaux sociaux (vidéos, infographie etc de sensibilisation et de vulgarisation …) **Consommation / Production secondaire** : recherches internet, avis sur les praticiens
Science	**Production** : institutions publiques (données issues de laboratoires, publications scientifiques, données météorologiques …) et entreprises	**Production / Consommation primaire** : science participative (observations, annotations de données …)

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

- Les données sont désormais produites massivement, en continu, par des sources extrêmement variées

Quelques chiffres clés ...

Chaque minute sur internet en 2022 (source)

- 1,7 million de contenus partagés sur Facebook
- 66 000 photos partagées sur Instagram
- 347 000 tweets postés sur Twitter
- 2,4 millions de snaps envoyés sur Snapchat
- 500 heures de vidéo uploadées sur YouTube
- 443 000 dollars dépensés sur Amazon

Chaque minute sur internet en 2024 (source)

- 5,9 millions de recherches effectuées sur Google
- 16,000 vidéos uploadées sur TikTok
- 18,8 millions de messages envoyés
- 251,1 millions de mails envoyés

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

- Les données sont désormais produites massivement, en continu, par des sources extrêmement variées

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

- Les données sont désormais produites massivement, en continu, par des sources extrêmement variées

  En hausse constante car de plus en plus de personnes dans le monde ont accès à Internet, et l'accès est de plus en plus rapide

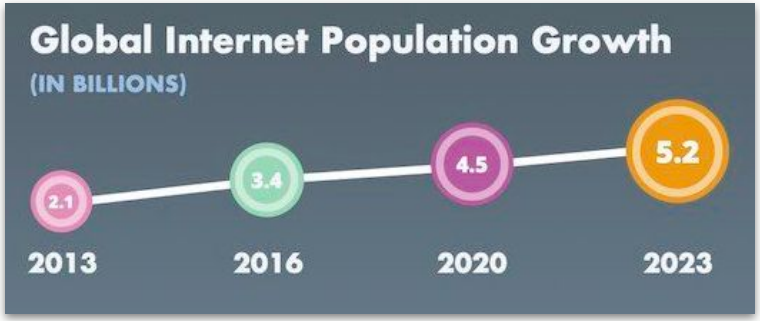
Global Internet Population Growth
(IN BILLIONS)
2.1
3.4
4.5
5.2
2013
2016
2020
2023

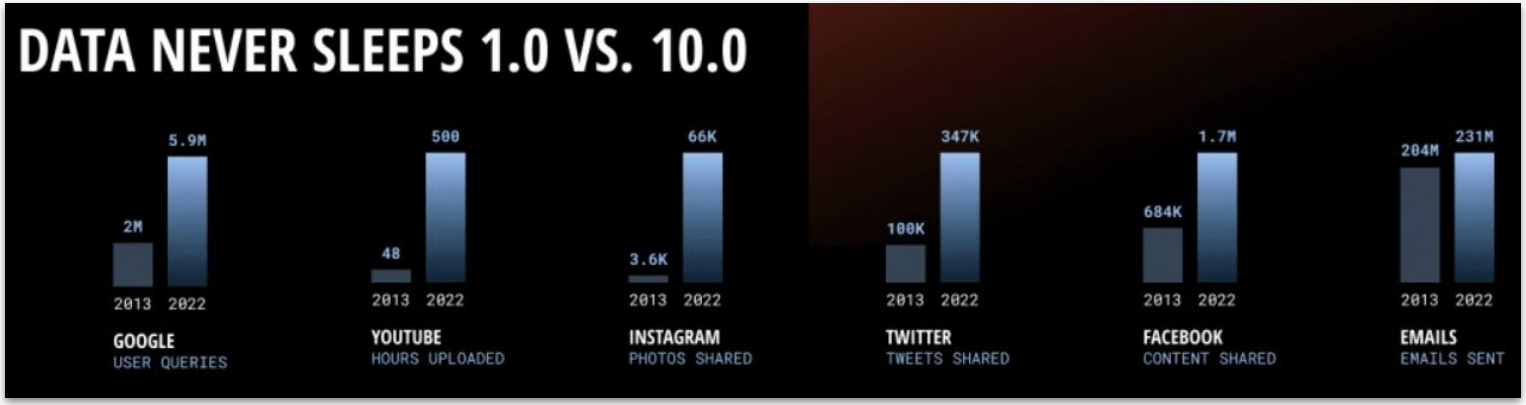
DATA NEVER SLEEPS 1.0 VS. 10.0
2M
5.9M
2013 2022
GOOGLE
USER QUERIES
48
500
2013 2022
YOUTUBE
HOURS UPLOADED
3.6K
66K
2013 2022
INSTAGRAM
PHOTOS SHARED
100K
347K
2013 2022
TWITTER
TWEETS SHARED
684K
1.7M
2013 2022
FACEBOOK
CONTENT SHARED
204M
231M
2013 2022
EMAILS
EMAILS SENT

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

- Les données sont désormais produites massivement, en continu, par des sources extrêmement variées

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

- Les données sont désormais produites massivement, en continu, par des sources extrêmement variées
- Ce changement de modèle et d'échelle est à la base des « Big Data » et de l'économie de la donnée

L'ère du Big Data

- Essor d'**Internet** et du **numérique**

  Le **modèle de production, de diffusion et de consommation des données** a changé :

  - Ancien modèle : **Centralisé**

    Quelques producteurs (médias traditionnels, entreprises, institutions publiques etc.), beaucoup de consommateurs.

  - Nouveau modèle : **Décentralisé**, participatif

    Chaque individu ou objet est à la fois générateur, actif ou passif, et consommateur de données.

- Les données sont désormais produites massivement, en continu, par des sources extrêmement variées
- Ce changement de modèle et d'échelle est à la base des « Big Data » et de l'économie de la donnée
- Le terme « Big Data » (mégadonnées ou données massives) est apparu en 1997

Chapitre 1. L'ère du Big Data

Chapitre 2. Big Data : Qu'est-ce-que c'est ?

Chapitre 3. Big Data : Pour quoi faire ?

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big » …

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity

caractéristiques & défis

- **Véracité**
  Veracity
- **Valeur**
  Value

défis

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Volume

Définition :

- À l'instant t : **Quantité massive** de données **produites et / ou stockées**
- Au fil du temps : **Croissance exponentielle** des données produites et / ou stockées

Octet	1 octet	8 bits, soit la possibilité de représenter 2^8 = 256 valeurs distinctes Table ASCII : 1 caractère = 1 octet	
Kilo-octet	10^3 octets		
Méga-octet	10^6 octets	1,44Mo : Disquette 3,5" 700Mo : Capacité d'un CD-ROM CD audio : 12cm, 74 minutes de musique (intégralité de la 9ème symphonie de Beethoven)	2Mo : une photo numérique haute résolution, 10Mo : 1 minute de son haute fidélité, 100Mo : le contenu d'une pile de livres de 1 mètre de haut
Giga-octet	10^9 octets	Plusieurs dizaines de Go : clés USB 4,7Go : Capacité de stockage d'un DVD simple couche 4-64 Go : Mémoire vive ordinateur 25-100Go : Capacité d'un disque blu-ray	20Go : Un enregistrement de l'œuvre complète de Beethoven
Téra-octet	10^{12} octets	1-8 To : disque dur ordinateur personnel	2To : tous les ouvrages d'une bibliothèque universitaire 10To : tous les imprimés de la bibliothèque du congrès américain 400To : la base de données du National Climatic Data Center
Peta-octet	10^{15} octets		2Po : les fonds de toutes les bibliothèques universitaires des états-unis 8Po : Données disponibles sur le web 20Po : l'ensemble des disques durs produits en 1995 200Po : l'ensemble des bandes magnétiques produites en 1995
Exa-octet	10^{18} octets		2Eo : le volume annuel des informations générées dans le monde 5Eo : tous les mots prononcés depuis le début de l'humanité

source : Les Echos (tableau de M. Alain Gely)

Octet	1 octet	8 bits, soit la possibilité de représenter 2^8 = 256 valeurs distinctes Table ASCII : 1 caractère = 1 octet	
Kilo-octet	10^3 octets		
Méga-octet	10^6 octets	1,44Mo : Disquette 3,5" 700Mo : Capacité d'un CD-ROM CD audio : 12cm, 74 minutes de musique (intégralité de la 9ème symphonie de Beethoven)	2Mo : une photo numérique haute résolution, 10Mo : 1 minute de son haute fidélité, 100Mo : le contenu d'une pile de livres de 1 mètre de haut
Giga-octet	10^9 octets	Plusieurs dizaines de Go : clés USB 4,7Go : Capacité de stockage d'un DVD simple couche 4-64 Go : Mémoire vive ordinateur 25-100Go : Capacité d'un disque blu-ray	20Go : Un enregistrement de l'œuvre complète de Beethoven
Téra-octet	10^{12} octets	1-8 To : disque dur ordinateur personnel	2To : tous les ouvrages d'une bibliothèque universitaire 10To : tous les imprimés de la bibliothèque du congrès américain 400To : la base de données du National Climatic Data Center
Peta-octet	10^{15} octets		2Po : les fonds de toutes les bibliothèques universitaires des états-unis 8Po : Données disponibles sur le web 20Po : l'ensemble des disques durs produits en 1995 200Po : l'ensemble des bandes magnétiques produites en 1995
Exa-octet	10^{18} octets		2Eo : le volume annuel des informations générées dans le monde 5Eo : tous les mots prononcés depuis le début de l'humanité

source : Les Echos (tableau de M. Alain Gely)

Big Data : Qu'est-ce que c'est ?

Volume

Définition :

- **À l'instant t** : Quantité massive de données **produites et / ou stockées**
- **Au fil du temps** : Croissance exponentielle des données **produites et / ou stockées**

Volume ≠ Quantité de données stockées

Trading à haute fréquence

- Flux **massif** de données à traiter en continu
  - Flux en temps réel des marchés financiers mondiaux
    Exemple : micro-variations de prix, de volume ou d'ordre
  - Signaux dérivés ou contextuels
    Exemple : écart de prix entre marchés, actualités économiques dans la presse, annonces
  - …

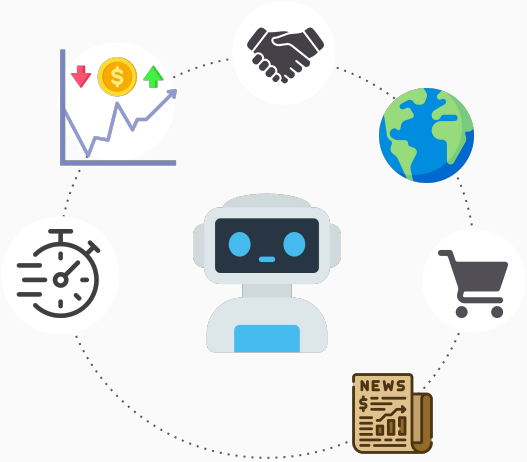

Trading à haute fréquence

- Flux **massif** de données à traiter en continu
  - Flux en temps réel des marchés financiers mondiaux
    Exemple : micro-variations de prix, de volume ou d'ordre
  - Signaux dérivés ou contextuels
    Exemple : écart de prix entre marchés, actualités économiques dans la presse, annonces
  - …
- Quantité **limitée** de données à stocker (à l'instant t)
  - Données réglementaires
    Exemple : ordres passés (identifiant, heure, prix, volume, instrument concerné …), transactions exécutées, modifications ou annulations d'ordre

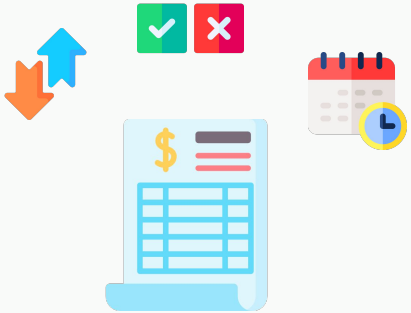

Trading à haute fréquence

- Flux **massif** de données à traiter en continu
  - Flux en temps réel des marchés financiers mondiaux
    Exemple : micro-variations de prix, de volume ou d'ordre
  - Signaux dérivés ou contextuels
    Exemple : écart de prix entre marchés, actualités économiques dans la presse, annonces
  - …
- Quantité **limitée** de données à stocker (à l'instant t)
  - Données réglementaires
    Exemple : ordres passés (identifiant, heure, prix, volume, instrument concerné …), transactions exécutées, modifications ou annulations d'ordre

Le « Volume » correspond ici à la quantité de données générées et traitées plutôt qu'à la quantité de données stockées.

Trading à haute fréquence

- Flux **massif** de données à traiter en continu
  - Flux en temps réel des marchés financiers mondiaux
    Exemple : micro-variations de prix, de volume ou d'ordre
  - Signaux dérivés ou contextuels
    Exemple : écart de prix entre marchés, actualités économiques dans la presse, annonces
  - …
- Quantité **limitée** de données à stocker (à l'instant t)
  - Données réglementaires
    Exemple : ordres passés (identifiant, heure, prix, volume, instrument concerné …), transactions exécutées, modifications ou annulations d'ordre

Le « Volume » correspond ici à la quantité de données générées et traitées plutôt qu'à la quantité de données stockées.

Sur le long terme en revanche, parler de données massives pour le stockage est pertinent.

Trading à haute fréquence

- Flux **massif** de données à traiter en continu
  - Flux en temps réel des marchés financiers mondiaux
    Exemple : micro-variations de prix, de volume ou d'ordre
  - Signaux dérivés ou contextuels
    Exemple : écart de prix entre marchés, actualités économiques dans la presse, annonces
  - …
- Quantité **limitée** de données à stocker (à l'instant t)
  - Données réglementaires
    Exemple : ordres passés (identifiant, heure, prix, volume, instrument concerné …), transactions exécutées, modifications ou annulations d'ordre

Le « Volume » correspond ici à la quantité de données générées et traitées plutôt qu'à la quantité de données stockées.

Sur le long terme en revanche, parler de données massives pour le stockage est pertinent.

Hôpital

- Production **modérée** de données
  - Examens individuels, chacun de taille modérée mais plusieurs centaines par jour
    Exemple : IRM, scanner, rayons X, échographie, dossier patient, tests en laboratoires

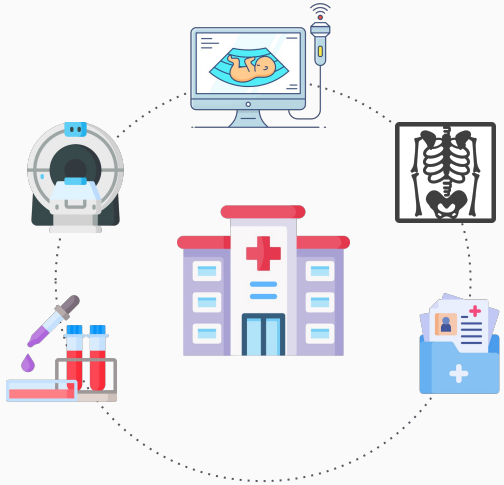

Trading à haute fréquence

- Flux **massif** de données à traiter en continu
  - Flux en temps réel des marchés financiers mondiaux
    Exemple : micro-variations de prix, de volume ou d'ordre
  - Signaux dérivés ou contextuels
    Exemple : écart de prix entre marchés, actualités économiques dans la presse, annonces
  - …
- Quantité **limitée** de données à stocker (à l'instant t)
  - Données réglementaires
    Exemple : ordres passés (identifiant, heure, prix, volume, instrument concerné …), transactions exécutées, modifications ou annulations d'ordre

Le « Volume » correspond ici à la quantité de données générées et traitées plutôt qu'à la quantité de données stockées.

Sur le long terme en revanche, parler de données massives pour le stockage est pertinent.

Hôpital

- Production **modérée** de données
  - Examens individuels, chacun de taille modérée mais plusieurs centaines par jour
    Exemple : IRM, scanner, rayons X, échographie, dossier patient, tests en laboratoires
- Quantité **massive** de données à stocker (au fil du temps)
  - Stockage à long terme pour des raisons cliniques, de recherche et de conformité
    Statistique : Selon le World Economic Forum, les hôpitaux produisent environ 50 pétaoctets de données par an (90% imagerie médicale)

Trading à haute fréquence

- Flux **massif** de données à traiter en continu
  - Flux en temps réel des marchés financiers mondiaux
    Exemple : micro-variations de prix, de volume ou d'ordre
  - Signaux dérivés ou contextuels
    Exemple : écart de prix entre marchés, actualités économiques dans la presse, annonces
  - …
- Quantité **limitée** de données à stocker (à l'instant t)
  - Données réglementaires
    Exemple : ordres passés (identifiant, heure, prix, volume, instrument concerné …), transactions exécutées, modifications ou annulations d'ordre

Le « Volume » correspond ici à la quantité de données générées et traitées plutôt qu'à la quantité de données stockées.

Sur le long terme en revanche, parler de données massives pour le stockage est pertinent.

Hôpital

- Production **modérée** de données
  - Examens individuels, chacun de taille modérée mais plusieurs centaines par jour
    Exemple : IRM, scanner, rayons X, échographie, dossier patient, tests en laboratoires
- Quantité **massive** de données à stocker (au fil du temps)
  - Stockage à long terme pour des raisons cliniques, de recherche et de conformité
    Statistique : Selon le World Economic Forum, les hôpitaux produisent environ 50 pétaoctets de données par an (90% imagerie médicale)

Le « Volume » correspond ici à la quantité de données accumulées au cours du temps plutôt qu'à la quantité de données générées.

Big Data : Qu'est-ce que c'est ?

Volume

Définition :

- À l'instant t : **Quantité massive** de données **produites et / ou stockées**
- Au fil du temps : **Croissance exponentielle** des données produites et / ou stockées

Big Data : Qu'est-ce que c'est ?

Volume

Définition :

- À l'instant t : **Quantité massive** de données **produites et / ou stockées**
- Au fil du temps : **Croissance exponentielle** des données produites et / ou stockées

Défis :

- Comment stocker les données ? (capacité, scalabilité, coût)
- Comment accéder efficacement aux données ? (performance : volume)
- Comment traiter efficacement les données ? (performance : volume)

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
  Exemple : 12 ans vs. "adolescent"

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
  Exemple : vidéo d'un discours vs. podcast d'un discours vs. transcription du discours vs. photos lors du discours

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle …

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
  - Structurées
    Exemple : tableau de données financières, base client
    dont données géographiques
    Exemple : données cadastrales

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
  - Structurées dont données géographiques
  - Semi-structurées
    Exemple : dossier médical, mail, pages web

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
  - Structurées dont données géographiques
  - Semi-structurées
  - Non structurées :
    - Texte libre

      Exemple : avis sur internet, contenu du chapitre d'un livre

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
  - Structurées dont données géographiques
  - Semi-structurées
  - Non structurées :
    - Texte libre
    - Graphe

      Exemple : graphe des pages web, utilisé par les moteurs de recherche ; graphe des interactions entre protéines

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
  - Structurées dont données géographiques
  - Semi-structurées
  - Non structurées :
    - Texte libre
    - Graphe
    - Images
    - Vidéos
    - Son

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
- Diversité de disponibilité

  Exemple : données accessibles en continu vs. de façon intermittente

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
- Diversité de disponibilité
- Diversité de source

  Exemple : données produites par différents capteurs dans les voitures autonomes (caméras, radars, LiDARSs, sonars)

Big Data : Qu'est-ce que c'est ?

Variété

Définition :

- Diversité sémantique
- Diversité de média
- Diversité structurelle
- Diversité de disponibilité
- Diversité de source

Défis :

- Comment combiner des données variées provenant de différentes sources ?

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Vélocité

Définition :

- Vitesse à laquelle les données sont générées

  Données statiques

  Exemple : images du ciel collectées en une nuit par la caméra LSST de l'observatoire Vera C. Rubin

  Données dynamiques / en temps réel

  Exemple : données produites par les capteurs d'une chaîne de production, utilisées pour de la maintenance prédictive

Big Data : Qu'est-ce que c'est ?

Vélocité

Définition :

- Vitesse à laquelle les données sont générées
- Vitesse à laquelle les données doivent être stockées
- Vitesse à laquelle les données doivent être traitées

Big Data : Qu'est-ce que c'est ?

Vélocité

Définition :

- Vitesse à laquelle les données sont générées
- Vitesse à laquelle les données doivent être stockées
- Vitesse à laquelle les données doivent être traitées

Défis :

- Comment stocker efficacement les données ? (performance : rapidité)
- Comment traiter efficacement les données ? (performance : rapidité)

Big Data : Qu'est-ce que c'est ?

Vélocité

Définition :

- Vitesse à laquelle les données sont générées
- Vitesse à laquelle les données doivent être stockées
- Vitesse à laquelle les données doivent être traitées

Défis :

- Comment stocker efficacement les données ? (performance : rapidité)
- Comment traiter efficacement les données ? (performance : rapidité)
- Comment faire coïncider la vitesse de traitement et la vitesse de production des données ?

  Traitement par lot (batch processing) vs. Traitement en temps réel (real-time processing)

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Véracité

Définition :

- Qualité et fiabilité des données
  Exemple : biais, bruit, incertitude, données manquantes, duplication, incohérence …

Défis :

- Comment évaluer et garantir la qualité de données massives, variées et parfois générées très rapidement ?

Sans véracité, les informations produites à partir des données risquent d'être **faussées ou inutilisables**.

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Les « Big data » ne sont pas seulement « Big ». Les cinqs dimensions (**5Vs**) des Big Data sont :

- **Volume**
  Volume
- **Variété**
  Variety
- **Vélocité**
  Velocity
- **Véracité**
  Veracity
- **Valeur**
  Value

Big Data : Qu'est-ce que c'est ?

Valeur

Définition :

- Contribution des données à la réalisation des objectifs

Big Data : Qu'est-ce que c'est ?

Valeur

Définition :

- Contribution des données à la réalisation des objectifs

  Accumuler des données n'a aucun intérêt en soi, pas plus qu'entasser du ciment.

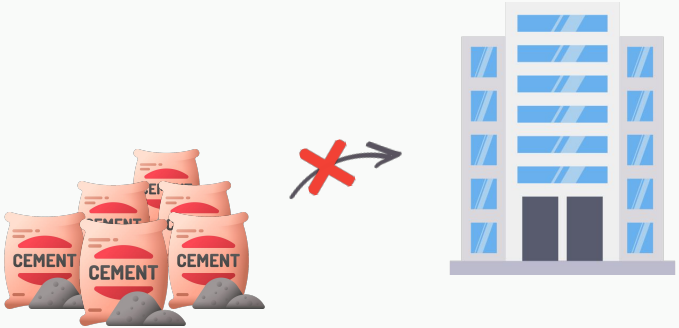

Big Data : Qu'est-ce que c'est ?

Valeur

Définition :

- Contribution des données à la réalisation des objectifs

  Accumuler des données n'a aucun intérêt si ces données ne sont pas converties en informations utiles à la réalisation d'un objectif.

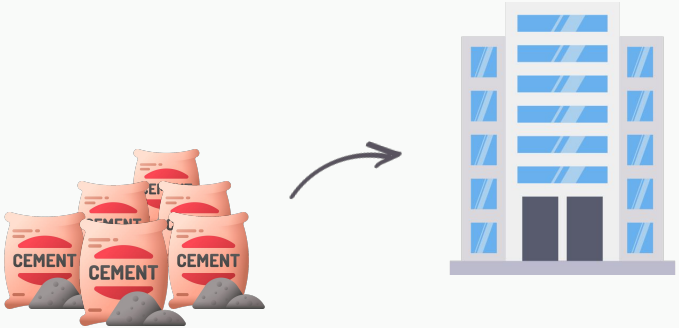

«

Data is not information,

Information is not knowledge,

Knowledge is not understanding,

Understanding is not **Wisdom.**

»

—

Russell Ackoff, Cliff Stoll

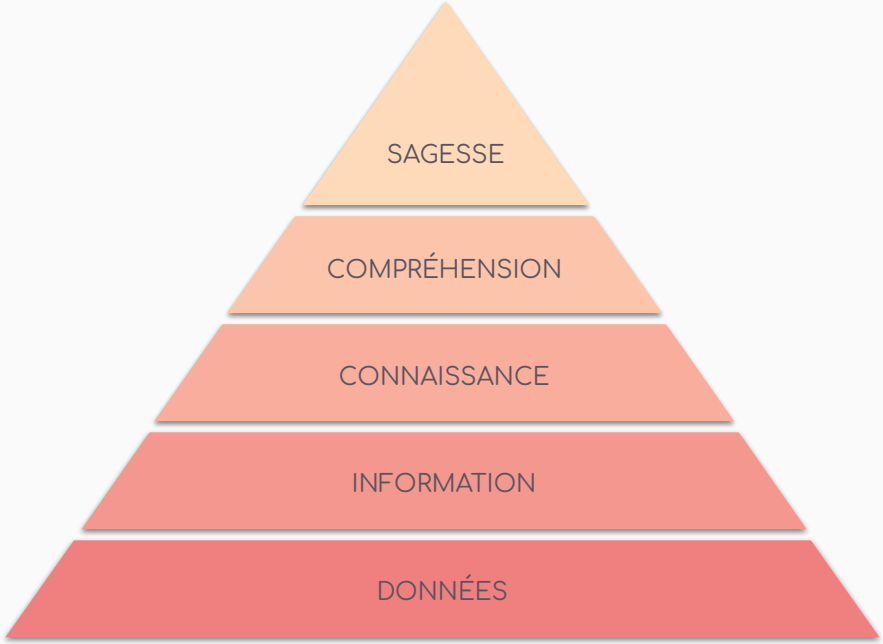

Données : la matière brute

- Faits bruts, non traités, généralement dépourvus de contexte ou de signification immédiate

DONNÉES

Données : la matière brute

- Faits bruts, non traités, généralement dépourvus de contexte ou de signification immédiate

Exemple :

livre, téléphone, location de voiture ?

ID client	ID produit	date	montant	...
C-644e4	P-RTE45	01/03/2018	123	

1er mars 2018 ou 3 janvier 2018 ?

$, €, ¥ ?

a priori, catalogue de transactions

Information : les données traitées et mises en contexte

- Données contextualisées, filtrées, organisées, nettoyées

  Qui, Quoi, Quand, Où, Combien

- Données présentées de manières intelligible

  Exemple : tableau de bord, rapport synthétique

- **Objectif** : convertir les données en informations exploitables

Information : les données traitées et mises en contexte

- Données contextualisées, filtrées, organisées, nettoyées
- Données présentées de manières intelligible
- **Objectif** : convertir les données en informations exploitables

total des ventes par jour

produits les plus vendus ce mois-ci

répartition des ventes par catégorie de produit

« En octobre 2025, 15 000 unités vendues dans la catégorie Téléphonie, générant 300 000 € de chiffre d'affaires »

Exemple :

historique des ventes de produits électroniques

entreprise américaine

ID client	ID produit	date	montant	...
C-644e4	P-RTE45	01/03/2018	123	
		3 janvier 2018	$	

Connaissance : l'information analysée et assimilée

- Résultat du croisement et de l'analyse des informations

  Comment

  Exemple : tendance, motifs récurrents, règles généralisables …

- **Objectif** : transformer les informations en connaissances actionnables

- La connaissance permet d'anticiper, de prédire, d'agir

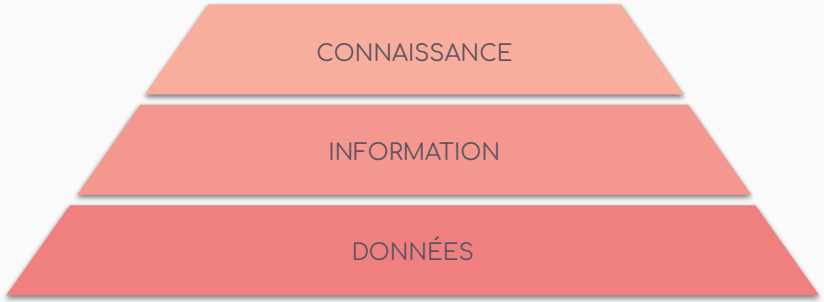

Connaissance : l'information analysée et assimilée

- Résultat du croisement et de l'analyse des informations
- **Objectif** : transformer les informations en connaissances actionnables
- La connaissance permet d'anticiper, de prédire, d'agir

motif récurrent

total des ventes par mois

2020
2021
2022
2023
2024

→

connaissance actionnable

chaque année, les ventes de smartphones sont 30% plus élevées en novembre

→

en novembre 2025, une hausse similaire pourrait se produire

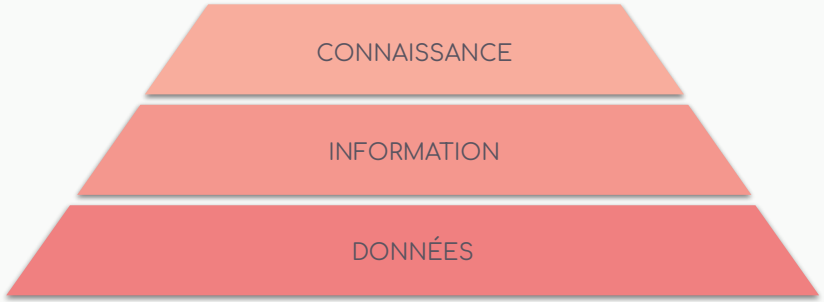

Compréhension : le « pourquoi » sous-jacent

- Appréciation des mécanismes sous-jacents
- **Objectif** : relier la connaissance à ses causes ou à des modèles explicatifs plus larges
- Comprendre le pourquoi permet de valider la connaissance et de la généraliser à d'autres contextes

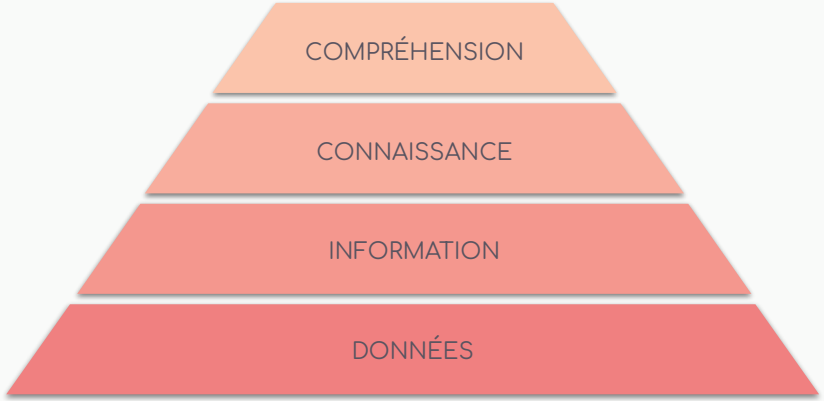

Compréhension : le « pourquoi » sous-jacent

- Appréciation des mécanismes sous-jacents
- **Objectif** : relier la connaissance à ses causes ou à des modèles explicatifs plus larges
- Comprendre le pourquoi permet de valider la connaissance et de la généraliser à d'autres contextes

Chaque année, les ventes de smartphones sont 30% plus élevées en novembre

pourquoi ?

- achats pré-fêtes
- mois du Black Friday et promotions pré-fêtes
- lancements de nouveaux modèles à l'automne par les grands fabricants

La hausse n'est pas due au hasard. Si le contexte change, le motif observé pourrait lui aussi changer.

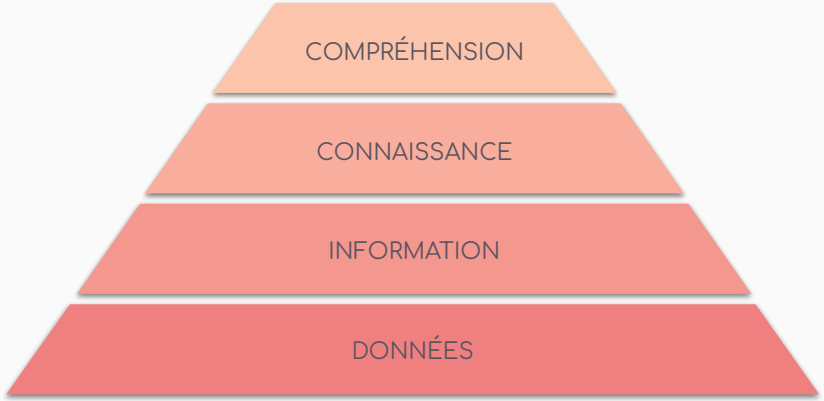

Sagesse : la décision stratégique avisée

- Prise de décision judicieuse à partir des connaissances et de la compréhension acquises

  Quoi faire, Pourquoi faire

- Les données, les informations et les connaissances décrivent surtout le passé ou le présent, la sagesse concerne l'action future

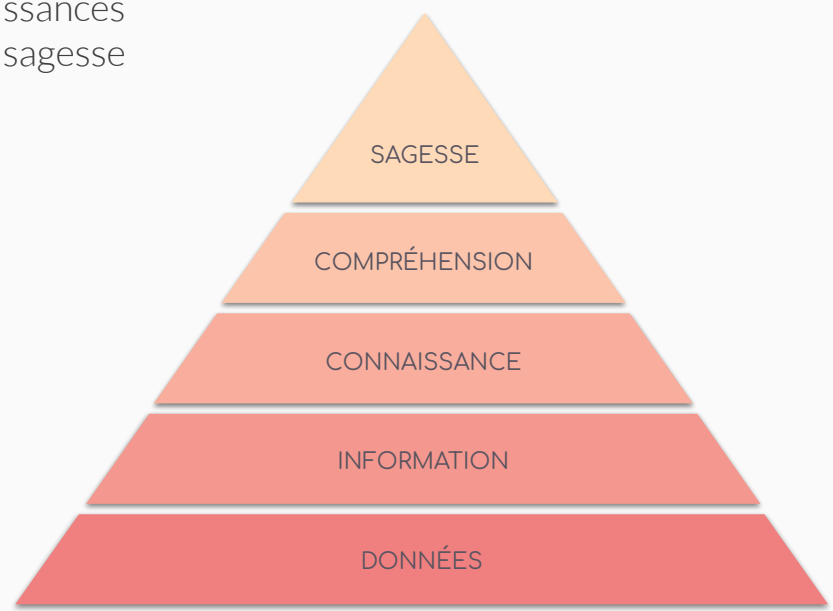

Sagesse : la décision stratégique avisée

- Prise de décision judicieuse à partir des connaissances et de la compréhension acquises
- Les données, les informations et les connaissances décrivent surtout le passé ou le présent, la sagesse concerne l'action future

Chaque année, les ventes de smartphones sont 30% plus élevées en novembre (fêtes, Black Friday, lancement de nouveaux produits par les fabricants)

quoi faire ? pourquoi faire ?

- Planifier à l'avance des stocks suffisants de smartphones pour satisfaire la demande accrue
- Investir davantage en publicité ciblée en octobre/novembre pour maximiser les profits durant cette période propice

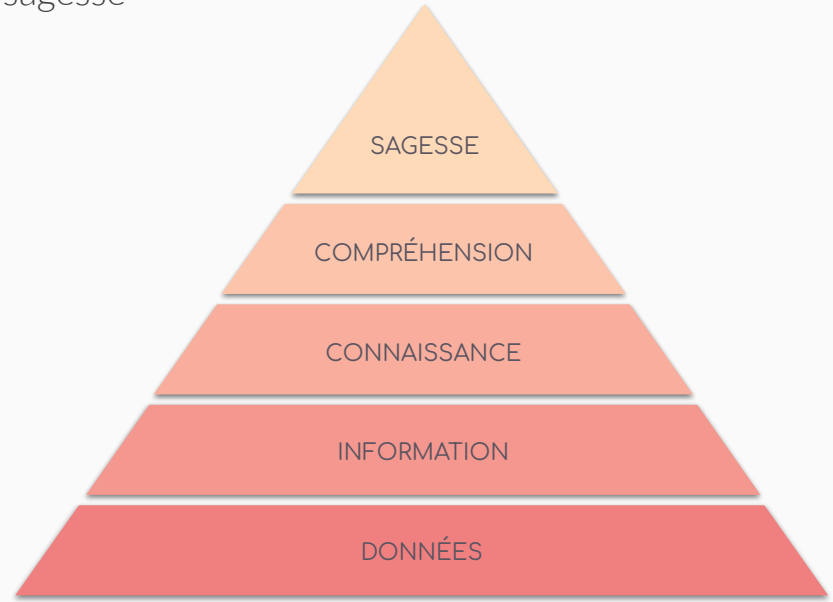

Big Data : Qu'est-ce que c'est ?

Valeur

Définition :

- Contribution des données à la réalisation des objectifs

Big Data : Qu'est-ce que c'est ?

Valeur

Définition :

- Contribution des données à la réalisation des objectifs

Défis :

- Comment produire de la valeur à partir de données massives, variées et parfois générées très rapidement ?

Des données massives, variées, éventuellement produites en temps réel, et de bonne qualité, représentent un atout majeur … si elles sont **utiles pour l'objectif poursuivi**.

Big Data : Qu'est-ce que c'est ?

En résumé ...

Le **Big Data** désigne des **données massives** dont le **volume**, la **vitesse** et/ou la grande **diversité** excèdent les capacités des méthodes de stockage et de traitement traditionnelles par les **nouveaux défis** qu'elles posent.

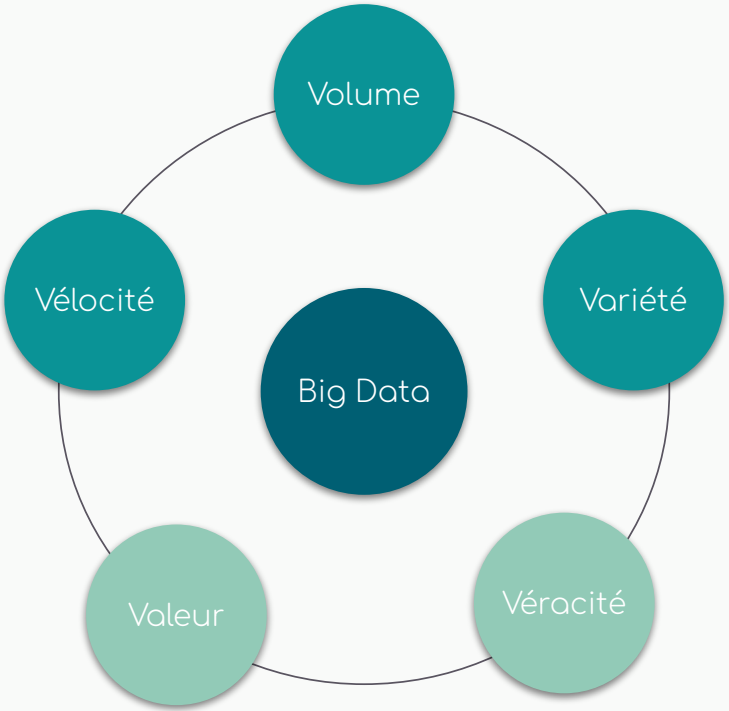

Big Data : Qu'est-ce que c'est ?

Remarque

Vous entendrez parfois parler des 7 Vs.

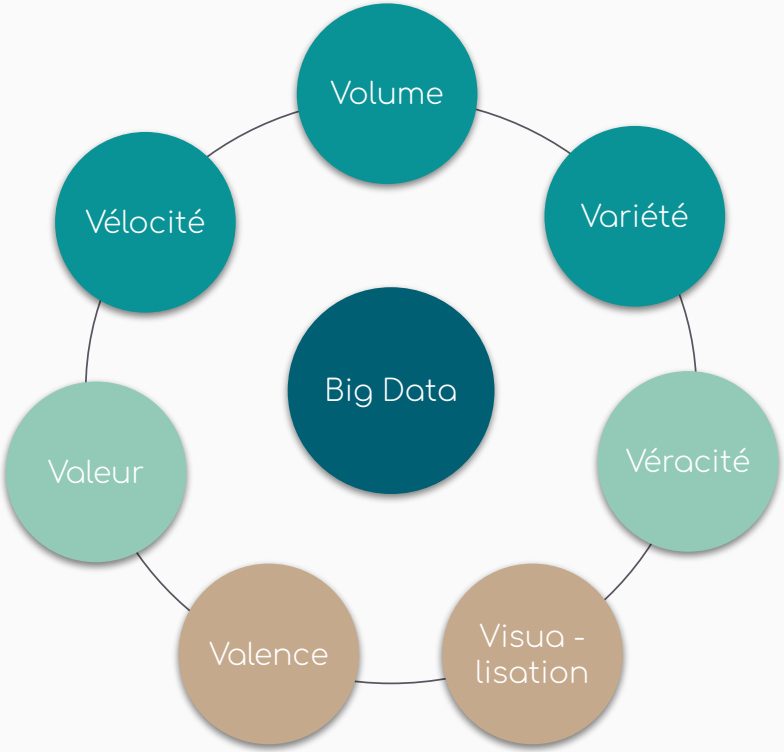

Chapitre 1. L'ère du Big Data

Chapitre 2. Big Data : Qu'est-ce-que c'est ?

Chapitre 3. Big Data : Pour quoi faire ?

Big Data : Pour quoi faire ?

- Les exemples d'utilisation du Big Data sont nombreux et couvrent plusieurs domaines :
  - Banque, Finance et Assurance
  - Commerce de détail
  - Télécommunications
  - Santé
  - Marketing et Divertissement
  - Transport et logistique
  - Industrie automobile
  - …
- L'exploitation des Big Data repose souvent sur du machine learning ou du deep learning

Big Data : Pour quoi faire ?

Banque

- **Détection de fraudes** : détecter en temps réel les activités suspectes parmi une quantité massive de :
  - données transactionnelles
    exemple : vitesse de dépense habituelle, heures et jours habituels de transaction, montant habituel des transactions, délai entre des lieux de paiement géographiquement dispersés
  - données non monétaires
    exemple : changement d'adresse, demande d'une nouvelle carte de crédit, réinitialisation récente du mot de passe

Big Data : Pour quoi faire ?

Banque

- **Détection de fraudes** : détecter en temps réel les activités suspectes parmi une quantité massive de données transactionnelles et non monétaires
- **Analyse des risques - Credit scoring** : évaluer la solvabilité d'un individu à partir de :
  - données monétaires
    exemples : l'historique de ses prêts, de ses remboursement, de ses transactions, de ses revenus
  - données démographiques
    exemple : tranche d'âge, emploi, lieu de vie
  - autres sources de données, plus controversées ("all data is credit data")
    exemple : achats réalisés par les consommateurs, réseaux sociaux (dont contacts : "solvabilité par association"), comportement de navigation en ligne, factures d'électricité, factures de téléphone

Big Data : Pour quoi faire ?

Finance

- **Trading Haute Fréquence** : anticiper les micro-mouvements de marché et en tirer profit en transmettant automatiquement et à très grande vitesse des ordres sur les marchés financiers
  - flux de données de marché
    exemples : micro-variations de prix, de volume ou d'ordre, carnets d'ordres complets, latences

Big Data : Pour quoi faire ?

Finance

- **Trading Haute Fréquence** : anticiper les micro-mouvements de marché et en tirer profit en transmettant automatiquement et à très grande vitesse des ordres sur les marchés financiers
  - flux de données de marché
  - données dérivées
    exemples : liquidité du marché, volatilité instantanée, écart de prix entre marchés mondiaux, probabilité d'exécution d'un ordre

Big Data : Pour quoi faire ?

Finance

- **Trading Haute Fréquence** : anticiper les micro-mouvements de marché et en tirer profit en transmettant automatiquement et à très grande vitesse des ordres sur les marchés financiers
  - flux de données de marché
  - données dérivées
  - données contextuelles
    exemples : actualités économiques (news, annonces…), tweets, données inter-marchés (corrélation…)

Big Data : Pour quoi faire ?

Finance

- **Trading Haute Fréquence** : anticiper les micro-mouvements de marché et en tirer profit en transmettant automatiquement et à très grande vitesse des ordres sur les marchés financiers
  - flux de données de marché
  - données dérivées
  - données contextuelles
  - signaux internes des algorithmes
    exemples : latence réseau, files d'attente internes, taux d'exécution, erreurs ou retards dans la transmission des ordres

Big Data : Pour quoi faire ?

Industrie automobile

- **Véhicule autonome** : percevoir à chaque instant l'environnement du véhicule et tout ce qui le compose (marquage au sol, panneaux, autres véhicules, piétons, conditions météo etc.), ainsi que l'état et la dynamique du véhicule, pour une conduite autonome, grâce à différents capteurs :
    - Caméra (majorité des données), lidars, radars, sonars, GPS etc.
    - Capteur de vitesse, capteur de pression de l'hydraulique des freins, capteur d'angle de braquage etc.
    - Éventuellement : données de trafic, données météorologiques, données sur le conducteur et les passagers etc.

Big Data : Pour quoi faire ?

Marketing

- **Publicité personnalisée** : recommander des produits ou des services en fonction du profil du client, déterminé à partir de :
  - données démographiques
  - interactions avec le service client
  - historique des produits ou services recherchés, des commandes passées, du panier d'achat
  - comportement de navigation (cookies)
  - réseaux sociaux (mentions j'aime, évaluations postées …)
  - localisation
  - etc.

Big Data : Pour quoi faire ?

Commerce de détail

- **Veille e-réputation** : protéger et améliorer la réputation d'une organisation en surveillant les informations qui circulent en ligne sur l'organisation, son image de marque ou ses représentants, de façon à identifier rapidement les signaux négatifs (critiques, fausses informations, attaques) comme positifs (témoignages clients, publications d'influenceurs, mentions spontanées)
    - publications, commentaires, hashtags, discussion, like / dislike, articles de journaux etc.

      remarque : l'analyse de sentiment (ou opinion mining) permet de déterminer si un texte exprime un sentiment positif, négatif ou neutre !

Big Data : Pour quoi faire ?

Santé

- **Développement de médicaments, de traitement et de vaccins** : accélérer la découverte de nouveaux médicaments, traitements ou vaccins grâce aux :
  - données cliniques
    exemple : données démographique, prise en charge, compte-rendus médicaux, interventions cliniques
  - données médicales
    exemple : imagerie médicale, analyses de laboratoire
  - données biologiques
    exemple : séquences d'ADN, séquence d'acides aminés de protéines connues

Big Data : Pour quoi faire ?

Santé

- **Développement de médicaments, de traitement et de vaccins** : accélérer la découverte de nouveaux médicaments, traitements ou vaccins grâce aux :
  - données cliniques
    exemple : données démographique, prise en charge, compte-rendus médicaux, interventions cliniques
  - données médicales
    exemple : imagerie médicale, analyses de laboratoire
  - données biologiques
    exemple : séquences d'ADN, séquence d'acides aminés de protéines connues
- Mais aussi : **aide au diagnostic**, **détection précoce de maladies**, **détection** via les réseaux sociaux **d'effets secondaires ou de mauvaise utilisation d'un médicament** etc.

Big Data : Pour quoi faire ?

Industrie

- **Maintenance prédictive** : anticiper en temps réel les pannes ou les besoins en maintenance des équipements grâce aux données collectées par des capteurs
- **Contrôle qualité continu** : identifier les défauts tôt dans le processus de production afin de corriger rapidement les problèmes et de réduire les taux de rebut

Dans la suite …

Volume

- Stockage
- Traitement

MERCI