Programmation statistique automatisée

BUT Science des Données - Metz

Berhocoïrigoin Elena

Avant-propos

- N'hésitez pas à poser des questions avant, pendant, après

Objectifs

Python pour …

- Lecture de données
- Traitement de données
- Extraction d'informations (via statistiques, graphiques)
- Automatisation des traitements

Récapitulatif

Numpy & Pandas

- Numpy :
  - Package Python
  - Numpy est la brique de base de l'écosystème Python dédié aux données
  - Objet principal : ?
- Pandas :
  - Package Python construit à partir de Numpy
  - Pandas simplifie le travail de traitement et d'analyse des données
  - Objet principal : ?

Numpy & Pandas

- Numpy :
  - Package Python
  - Numpy est la brique de base de l'écosystème Python dédié aux données
  - Objet principal : **Array**
- Pandas :
  - Package Python construit à partir de Numpy
  - Pandas simplifie le travail de traitement et d'analyse des données
  - Objet principal : **DataFrame**

indices de position

implicite

0 1 2 3

0

1

2

3

valeur	valeur	valeur	valeur
valeur	valeur	valeur	valeur
valeur	valeur	valeur	valeur
valeur	valeur	valeur	valeur

type A

Array Numpy

indices de position

implicite

?

	0	1	2	3
	label 0	label 1	label 2	label 3
0	label 0	valeur	valeur	valeur	valeur
1	label 1	valeur	valeur	valeur	valeur
2	label 2	valeur	valeur	valeur	valeur
3	label 3	valeur	valeur	valeur	valeur

labels de colonnes

explicite

?

Series

labels de lignes

explicite

?

DataFrame

Pandas

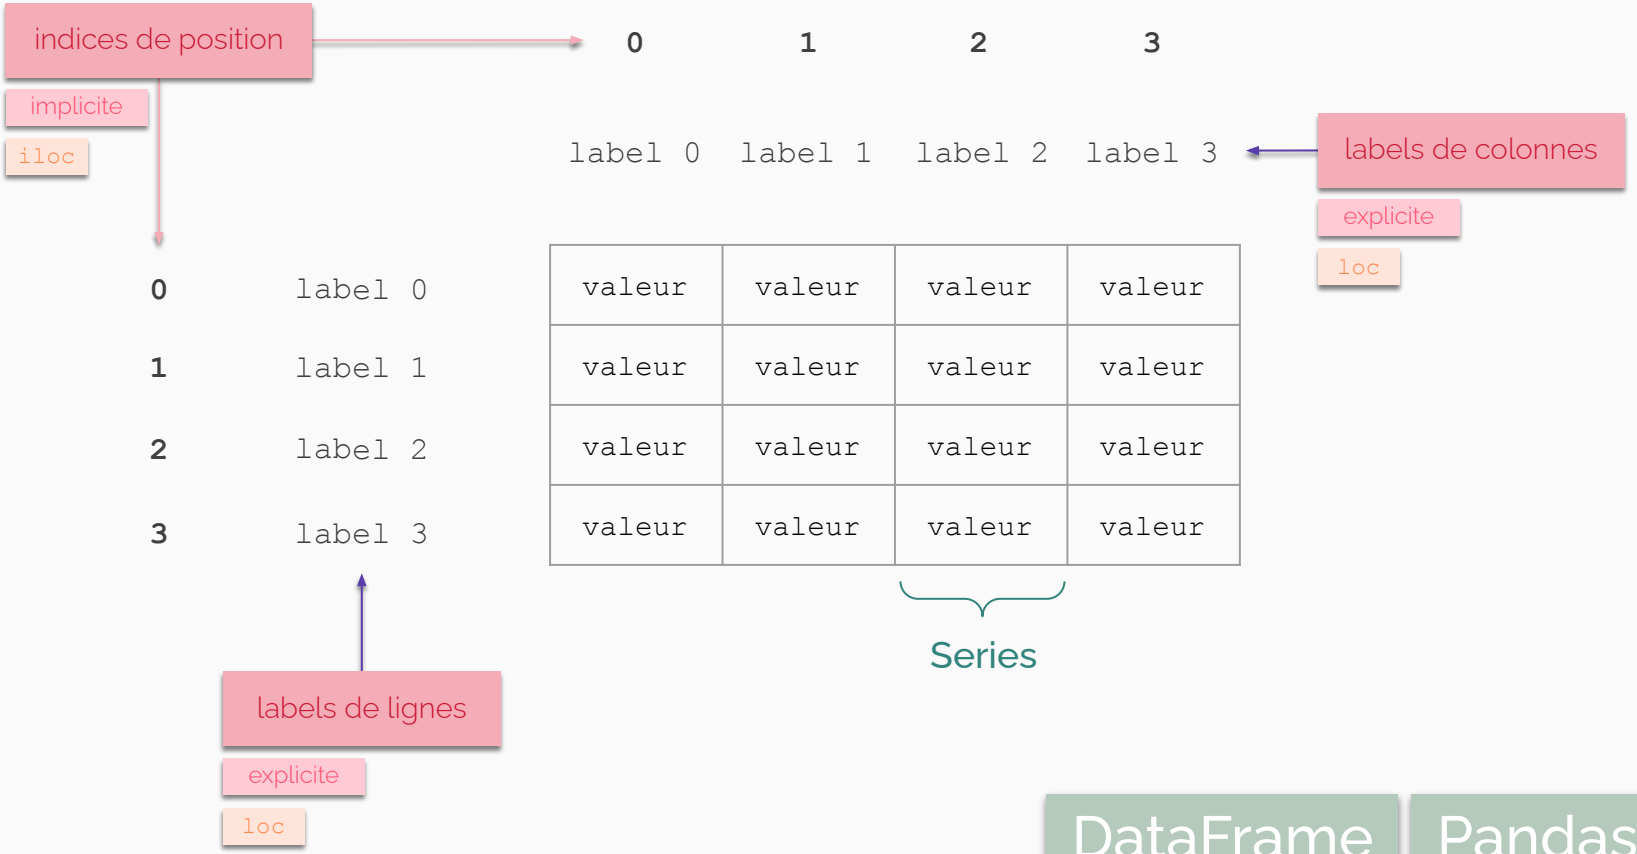
indices de position
implicite
iloc
0
1
2
3
label 0
label 1
label 2
label 3
labels de colonnes
explicite
loc
0
1
2
3
label 0
label 1
label 2
label 3
valeur
Series
labels de lignes
explicite
loc
DataFrame
Pandas

indices de position

implicite

iloc

labels de colonnes

explicite

loc

		0	1	2	3
		jour	mois	annee	age
0	Tom	1	12	2003	21
1	Paule	4	5	1996	29
2	Sophie	7	8	1967	58
3	Eden	10	11	2012	12

labels de lignes

explicite

loc

```
df.iloc[2,1]

df.loc["Sophie","mois"]
```

indices de position

implicite

iloc

labels de colonnes

explicite

loc

		0	1	2	3
		jour	mois	annee	age
0	Tom	1	12	2003	21
1	Paule	4	5	1996	29
2	Sophie	7	8	1967	58
3	Eden	10	11	2012	12

labels de lignes

explicite

loc

```
df.iloc[2,1:3]
```

```
df.loc["Sophie","mois":"annee"]
```

indices de position

implicite

iloc

labels de colonnes

explicite

loc

		0	1	2	3
		jour	mois	annee	age
0	Tom	1	12	2003	21
1	Paule	4	5	1996	29
2	Sophie	7	8	1967	58
3	Eden	10	11	2012	12

labels de lignes

explicite

loc

```
df.iloc[2,1:3]
df.iloc[2,[1,2]]
```

```
df.loc["Sophie","mois":"annee"]
df.loc["Sophie",["mois","annee"]]
```

indices de position

implicite

iloc

labels de colonnes

explicite

loc

labels de lignes

explicite

loc

		0	1	2	3
		jour	mois	annee	age
0	Tom	1	12	2003	21
1	Paule	4	5	1996	29
2	Sophie	7	8	1967	58
3	Eden	10	11	2012	12

```
df[df["annee"] >= 2000]

df.loc[df["annee"] >= 2000,:]
```

indices de position

implicite

iloc

labels de colonnes

explicite

loc

labels de lignes

explicite

loc

		0	1	2	3
		jour	mois	annee	age
0	Tom	1	12	2003	21
1	Paule	4	5	1996	29
2	Sophie	7	8	1967	58
3	Eden	10	11	2012	12

```
df.loc[df["annee"] >= 2000,["annee","age"]]
```

Objectifs

Python pour …

- Lecture de données
- Traitement de données
- Extraction d'informations (via statistiques, graphiques)
- Automatisation des traitements

Plan

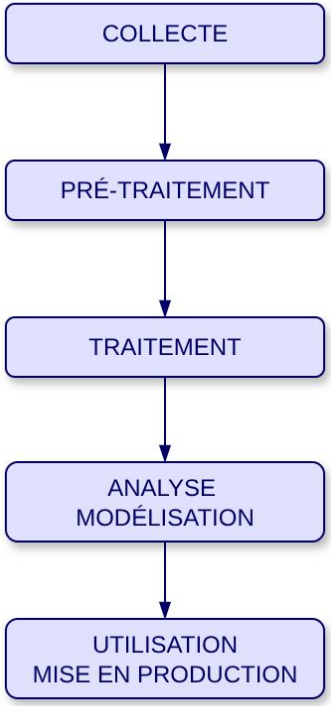

1. Collecter les données
2. Comprendre les données
3. Explorer les données
4. Traiter les données
5. Exploiter les données
6. Agir grâce aux données

Plan

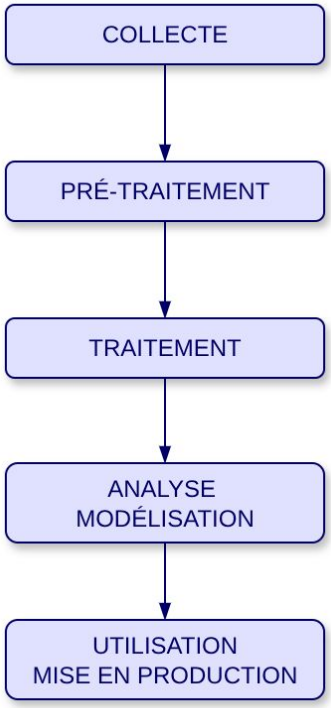

1. Collecter les données
2. Comprendre les données
3. Explorer les données
4. Traiter les données
5. Exploiter les données
6. Agir grâce aux données

Collecter les données - Trouver les données

- **Données internes** (1st party data) :
  - Données créées ou collectées en interne, en ligne ou hors ligne, sans intermédiaire

Collecter les données - Trouver les données

- **Données internes** (1st party data) :
  - Données créées ou collectées en interne, en ligne ou hors ligne, sans intermédiaire

    Exemple :
    - capteurs installés sur les lignes de production
    - interactions avec un site internet (via les cookies)
    - emails échangés avec le service client
    - sondages réalisé auprès d'un public cible
    - historique médical d'un patient …

Collecter les données - Trouver les données

- **Données internes** (1st party data) :
  - Données créées ou collectées en interne, en ligne ou hors ligne, sans intermédiaire
- **Données externes** (2nd party data, 3rd party data) :
  - Données créées ou collectées par une tierce partie, à qui elles appartiennent, et qui les vend ou les met à disposition gratuitement

Collecter les données - Trouver les données

- **Données internes** (1st party data) :
  - Données créées ou collectées en interne, en ligne ou hors ligne, sans intermédiaire
- **Données externes** (2nd party data, 3rd party data) :
  - Données créées ou collectées par une tierce partie, à qui elles appartiennent, et qui les vend ou les met à disposition gratuitement

    Exemple :
    - vente des données d'achat de voitures par le secteur automobile aux compagnies d'assurance
    - données météorologiques partagées en open data par Météo France

Collecter les données - Trouver les données

- **Données internes** (1st party data) :
  - Données créées ou collectées en interne, en ligne ou hors ligne, sans intermédiaire
- **Données externes** (2nd party data, 3rd party data) :
  - Données créées ou collectées par une tierce partie, à qui elles appartiennent, et qui les vend ou les met à disposition gratuitement
  - Données collectées par des intermédiaires, les agrégateurs de données, qui font généralement de l'achat-revente

Collecter les données - Trouver les données

- **Données internes** (1st party data) :
  - Données créées ou collectées en interne, en ligne ou hors ligne, sans intermédiaire
- **Données externes** (2nd party data, 3rd party data) :
  - Données créées ou collectées par une tierce partie, à qui elles appartiennent, et qui les vend ou les met à disposition gratuitement
  - Données collectées par des intermédiaires, les agrégateurs de données, qui font généralement de l'achat-revente

    Exemple :
    - liste de numéros de téléphone
    - données sur la biodiversité agrégées par GBIF et OBIS
    - comportements de navigation en ligne

Collecter les données - Lire les données

Une fois qu'on a identifié les données dont on a besoin, il faut pouvoir y accéder.

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers …

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers : fonction `read_csv()` de **Pandas**.

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers : fonction `read_csv()` de **Pandas**.

1. **Quel est le chemin d'accès du fichier ?**
   - Clic droit sur le fichier > Propriétés
   - Clic droit dans le dossier > Ouvrir dans le Terminal

```
import pandas as pd

df = pd.read_csv('chemin/vers/le/fichier', ...)
```

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers : fonction `read_csv()` de **Pandas**.

1. Quel est le chemin d'accès du fichier ?
2. **Quel est le délimiteur du fichier ?**
   - Fichier petit à moyen : ouvrir le fichier
   - Gros fichier : utiliser la fonction `open()` de Python pour ne lire que les premières lignes

```
nlignes = 2
with open('chemin/vers/le/fichier', 'r') as fichier:
  for i in range(nlignes):
    ligne = next(fichier).strip()
    print(ligne)
```

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers : fonction `read_csv()` de **Pandas**.

1. Quel est le chemin d'accès du fichier ?
2. **Quel est le délimiteur du fichier ?**

```
import pandas as pd

df = pd.read_csv('chemin/vers/le/fichier', sep='délimiteur', ...)
```

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers : fonction `read_csv()` de **Pandas**.

1. Quel est le chemin d'accès du fichier ?
2. Quel est le délimiteur du fichier ?
3. **Bonne pratique : Quel est le type de chacune des variables ?**

```
import pandas as pd

df = pd.read_csv('chemin/vers/le/fichier', sep='délimiteur', dtype={'nom de colonne':'type', ...}, ...)
```

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers : fonction `read_csv()` de **Pandas**.

1. Quel est le chemin d'accès du fichier ?
2. Quel est le délimiteur du fichier ?
3. Bonne pratique : Quel est le type de chacune des variables ?
4. **Exécuter la commande et affecter le résultat à une variable**

Collecter les données - Lire les données

En Python, à partir d'un ou plusieurs fichiers : fonction `read_csv()` de **Pandas**.

```
import pandas as pd

emissions = pd.read_csv('.../ges_territoire.csv', sep=',')
```

Plan

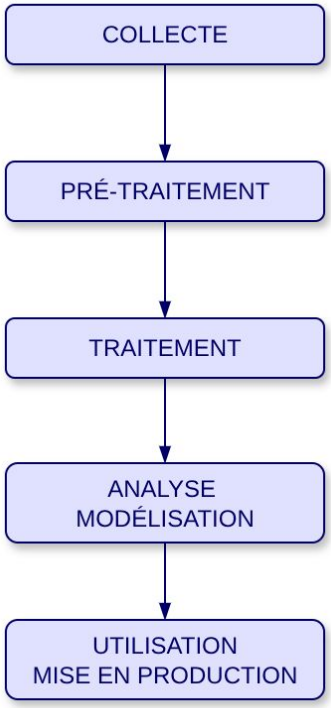

1. Collecter les données
2. Comprendre les données
3. Explorer les données
4. Traiter les données
5. Exploiter les données
6. Agir grâce aux données

«

Data is not information,

Information is not knowledge,

Knowledge is not understanding,

Understanding is not **Wisdom.**

»

—

Russell Ackoff, Cliff Stoll

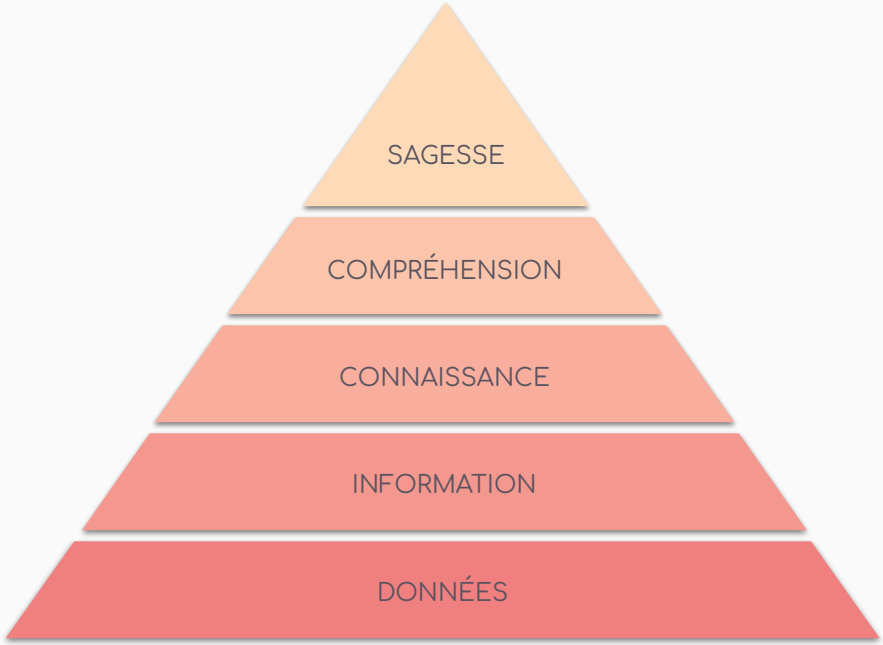

Plan

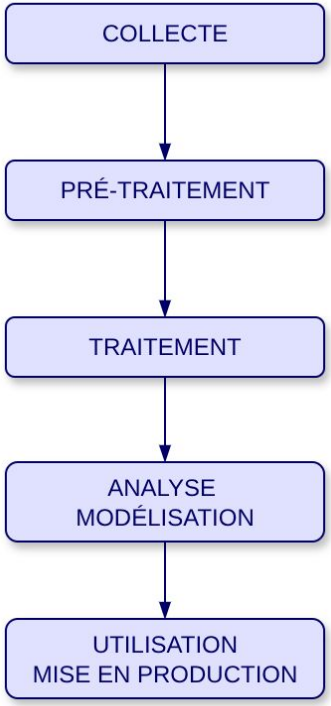

1. Collecter les données
2. Comprendre les données
3. Explorer les données
4. Traiter les données
5. Exploiter les données
6. Agir grâce aux données

Comprendre les données : Nature

- Données structurées, semi-structurées, non structurées ?

  Exemple :

Date : 29 août 2025

Heure : 09:42–09:45 (CEST, UTC+2) — **Durée** : 3 min

Canal : Téléphone (entrant)

Agent : Lina (SAV) — **Client** : Camille Dalida

Commande : #D44120 — Ticket : TCK-2025-08-29-0942

Transcription

[09:42:03] Client : Bonjour, j'appelle pour ma commande #D44120. Elle devait arriver hier mais je n'ai rien reçu.
[09:42:18] SAV : Bonjour Camille, je vérifie.
[09:42:20] SAV : Oui, le colis est en transit. La nouvelle livraison est prévue pour demain avant 18:00.
[09:43:02] Client : Très bien. Puis-je recevoir une notif quand le livreur approche ?
[09:43:15] SAV : Bien sûr. J'active le SMS de suivi. Vous devriez recevoir un mail de confirmation dans quelques minutes.
[09:44:28] Client : Merci pour votre aide.
[09:44:40] SAV : Avec plaisir ! Bonne journée.

Suivi

[09:44:55] Action agent :

- Alerte SMS activée
- Mail récapitulatif envoyé

GOUVERNEMENT
Liberté
Égalité
Fraternité

choisir le service public.gouv.fr

Demande de mobilité
au sein des services de l'administration territoriale de l'Etat

Demande de mutation ou de prise en charge

N° de l'offre sur Choisir le Service Public : _____ et/ou N° interne ministériel (RenoiRH, AGHORA, MOB MI, Passerelles) : _____

La demande est à adresser :

- au service RH de la structure de départ, par la voie hiérarchique
- au service RH de la structure d'accueil et aux personnes indiquées dans l'offre d'emploi (avec CV et lettre de motivation)

Situation personnelle

Nom : _____ Nom patronymique : _____ Prénom : _____
Adresse personnelle : _____
Date de naissance : _____
Nationalité : _____ N° de l'agent : _____
Adresse email professionnelle: _____
Téléphone : _____

Situation administrative

Statut : ☐ Fonctionnaire ☐ Contractuel
Position administrative : _____
Corps et Grade ou niveau de contrat : _____
Employeur : _____ Service d'affectation : _____
Adresse du service d'affectation : _____
Adresse email : _____ Téléphone : _____
Contact Rh du service d'affectation : _____

— IX —

mardi, 27 juin, et sous le titre : *Le Livre d'or de la Commune*, la publication d'un travail de M. Henri Duguiès, relatif aux membres, fonctionnaires et employés de la Commune.

« Or, de mon côté, j'ai fait également un travail sur ce même sujet, et qui est *absolument identique* à celui de votre collaborateur. Ce travail, qui doit paraître en un volume chez Dentu, éditeur au Palais-Royal, sous le titre de : *Les fonctionnaires de la Commune, liste alphabétique, extraite du Journal officiel de la Commune* (1), est en ce moment en cours d'impression chez M. Jouaust, 338, rue Saint-Honoré.

« Comme je tiens, d'une part, à ne point passer pour un plagiaire, et, d'autre part, à continuer ma publication, je vous prie de vouloir bien insérer cette lettre dans le plus prochain numéro de votre journal, lettre dont la publication doit prévenir, par avance, à cause de l'extrême ressemblance qui existe entre mon

(1) Ce titre a été, depuis, modifié sur la demande de mon éditeur.

Comprendre les données : Nature

- Données structurées, semi-structurées, non structurées ?

  Exemple :

Date : 29 août 2025

Heure : 09:42–09:45 (CEST, UTC+2) — **Durée** : 3 min

Canal : Téléphone (entrant)

Agent : Lina (SAV) — **Client** : Camille Dalida

Commande : #D44120 — Ticket : TCK-2025-08-29-0942

Transcription

[09:42:03] Client : Bonjour, j'appelle pour ma commande #D44120. Elle devait arriver hier mais je n'ai rien reçu.
[09:42:18] SAV : Bonjour Camille, je vérifie.
[09:42:20] SAV : Oui, le colis est en transit. La nouvelle livraison est prévue pour demain avant 18:00.
[09:43:02] Client : Très bien. Puis-je recevoir une notif quand le livreur approche ?
[09:43:15] SAV : Bien sûr. J'active le SMS de suivi. Vous devriez recevoir un mail de confirmation dans quelques minutes.
[09:44:28] Client : Merci pour votre aide.
[09:44:40] SAV : Avec plaisir ! Bonne journée.

Suivi

[09:44:55] Action agent :

- Alerte SMS activée
- Mail récapitulatif envoyé

données semi-structurées

GOUVERNEMENT
Liberté
Égalité
Fraternité

choisir le service public.gouv.fr

Demande de mobilité
au sein des services de l'administration territoriale de l'Etat

Demande de mutation ou de prise en charge

N° de l'offre sur Choisir le Service Public : _____ et/ou N° interne ministériel (RenoiRH, AGHORA, MOB MI, Passerelles) : _____

La demande est à adresser :

- au service RH de la structure de départ, par la voie hiérarchique
- au service RH de la structure d'accueil et aux personnes indiquées dans l'offre d'emploi (avec CV et lettre de motivation)

Situation personnelle

Nom : _____ Nom patronymique : _____ Prénom : _____
Adresse personnelle : _____
Date de naissance : _____
Nationalité : _____ N° de l'agent : _____
Adresse email professionnelle: _____
Téléphone : _____

Situation administrative

Statut : ☐ Fonctionnaire ☐ Contractuel
Position administrative : _____
Corps et Grade ou niveau de contrat : _____
Employeur : _____ Service d'affectation : _____
Adresse du service d'affectation : _____
Adresse email : _____ Téléphone : _____
Contact Rh du service d'affectation : _____

données structurées

— IX —

mardi, 27 juin, et sous le titre : *Le Livre d'or de la Commune*, la publication d'un travail de M. Henri Duguiès, relatif aux membres, fonctionnaires et employés de la Commune.

« Or, de mon côté, j'ai fait également un travail sur ce même sujet, et qui est *absolument identique* à celui de votre collaborateur. Ce travail, qui doit paraître en un volume chez Dentu, éditeur au Palais-Royal, sous le titre de : *Les fonctionnaires de la Commune, liste alphabétique, extraite du Journal officiel de la Commune* (1), est en ce moment en cours d'impression chez M. Jouaust, 338, rue Saint-Honoré.

« Comme je tiens, d'une part, à ne point passer pour un plagiaire, et, d'autre part, à continuer ma publication, je vous prie de vouloir bien insérer cette lettre dans le plus prochain numéro de votre journal, lettre dont la publication doit prévenir, par avance, à cause de l'extrême ressemblance qui existe entre mon

(1) Ce titre a été, depuis, modifié sur la demande de mon éditeur.

données non structurées

Comprendre les données : Nature

- Données structurées, semi-structurées, non structurées ?
  - **Outils** utilisables
    Exemple : images prises en charge par les CNNs, texte pris en charge par les LLMs

Comprendre les données : Nature

- Données structurées, semi-structurées, non structurées ?
  - **Outils** utilisables
    Exemple : images prises en charge par les CNNs, texte pris en charge par les LLMs
  - Nécessité d'un **prétraitement** si données semi-structurées ou non structurées en fonction de l'utilisation prévue
    Exemple : texte et régression linéaire

Comprendre les données : Nature

- Données structurées, semi-structurées, non structurées ?
  Dans ce cours : données structurées, i.e données qui se conforment naturellement au format tabulaire

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'**observations** (ou *enregistrements* ou *individus* ou *lignes*) et de **variables** (ou *colonnes*) ?

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'**observations** (ou *enregistrements* ou *individus* ou *lignes*) et de **variables** (ou *colonnes*) ?

```
# Nombre de lignes
df.shape[0]
# Nombre de colonnes
df.shape[1]
```

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.

```
# Cinq premières lignes
df.head(5)
# Cinq dernières lignes
df.tail(5)
```

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.

```
df.columns
```

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.

```
df.columns
```

Est-ce suffisant ?

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.

```
df.columns
```

Est-ce suffisant ?

Co^2 ? Année ?

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.

- Consulter la **documentation**
  - Comprendre le nom des variables
  - Contextualiser les données :
    - **qui ?** qualité, fiabilité, adéquation à l'usage
    - **quoi ?** compréhension, adéquation à l'usage
    - **quand ?** ancienneté / fraîcheur, mise à jour, adéquation à l'usage
    - **où ?** périmètre géographique, adéquation à l'usage
    - **comment ?** qualité, fiabilité, adéquation à l'usage
    - **pourquoi ?** compréhension

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.

- Consulter la **documentation**
  - Comprendre le nom des variables
  - Contextualiser les données : qui ? quoi ? quand ? où ? pourquoi ? comment ?

https://data.ademe.fr/datasets/igt-pouvoir-de-rechauffement-global

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.
- Consulter la **documentation**
  - Comprendre le nom des variables
  - Contextualiser les données : qui ? quoi ? quand ? où ? pourquoi ? comment ?

https://data.ademe.fr/datasets/igt-pouvoir-de-rechauffement-global

Est-ce suffisant ?

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.

- Consulter la **documentation**
  - Comprendre le nom des variables
  - Contextualiser les données : qui ? quoi ? quand ? où ? pourquoi ? comment ?

https://data.ademe.fr/datasets/igt-pouvoir-de-rechauffement-global

Vocabulaire spécialisé ?

Unité ?

Communes d'outre-mer ?

Comprendre les données : Contenu

- Afficher les **métadonnées**
  - Combien y a-t-il d'observations et de variables ?
  - À quoi correspondent les lignes ? Afficher les premières ou les dernières lignes.
  - Que nous apprennent le nom des variables ? Afficher le nom des colonnes.
- Consulter la **documentation**
  - Comprendre le nom des variables
  - Contextualiser les données : qui ? quoi ? quand ? où ? pourquoi ? comment ?
- Consulter des **ressources externes**
  - Rechercher les mots clés

Vocabulaire spécialisé ?

Unité ?

Communes d'outre-mer ?

Comprendre les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

Plan

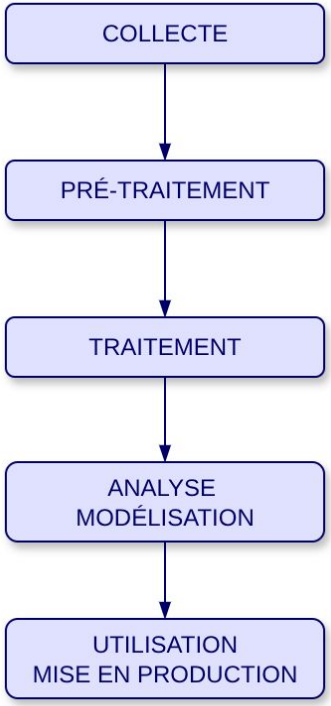

1. Collecter les données
2. Comprendre les données
3. Explorer les données
4. Traiter les données
5. Exploiter les données
6. Agir grâce aux données

Plan

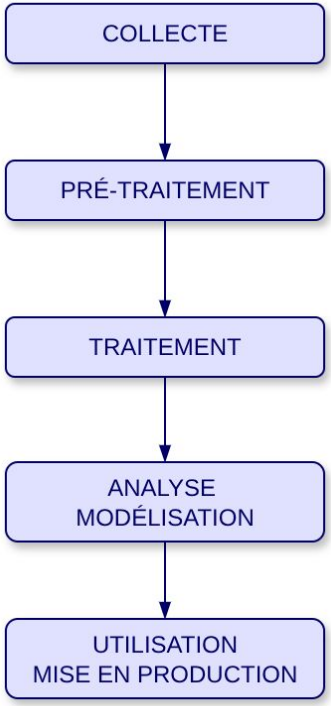

1. Collecter les données
2. Comprendre les données
3. Explorer les données
4. Traiter les données
5. Exploiter les données
6. Agir grâce aux données

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

Diagnostic « Qualité des données »

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
    Exemple : âge négatif ou au-delà de 122 (record du monde), très hauts revenus

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?

```
df.agg(['min','max'])
df.quantile([0.01,0.99], axis=0)
# Filtre logique pour identifier les valeurs aberrantes
```

Quantile empirique : valeur `p` qui partage une série statistique en sous-ensembles, chaque sous-ensemble contenant une proportion d'observations plus ou moins égale à `p`
Exemple : quantile 0.5 = deux sous-ensembles qui contiennent chacun environ 50% des données

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?

```
df.agg(['min','max'])
df.quantile([0.01,0.99], axis=0)
# Filtre logique pour identifier les valeurs aberrantes
```

Quantile empirique : valeur `p` qui partage une série statistique en sous-ensembles, chaque sous-ensemble contenant une proportion d'observations plus ou moins égale à `p`

Exemple : quantile 0.1 = ?

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?

```
df.agg(['min','max'])
df.quantile([0.01,0.99], axis=0)
# Filtre logique pour identifier les valeurs aberrantes
```

Quantile empirique : valeur `p` qui partage une série statistique en sous-ensembles, chaque sous-ensemble contenant une proportion d'observations plus ou moins égale à `p`
Exemple : quantile 0.1 = dix sous-ensembles qui contiennent chacun environ 10% des données

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?

```
Nuage de points (scatterplot)
Boîte à moustache (boxplot)
```

Graphiques en Python - Matplotlib

- **Matplotlib** :
  - Package Python
  - Construction de graphiques
  - Flexible mais pas toujours intuitif
  - Trois niveaux :
    - Figure : figure entière
    - Ax**es** : zone où insérer un graphique
    - Ax**is** : graduations et étiquettes de graduation

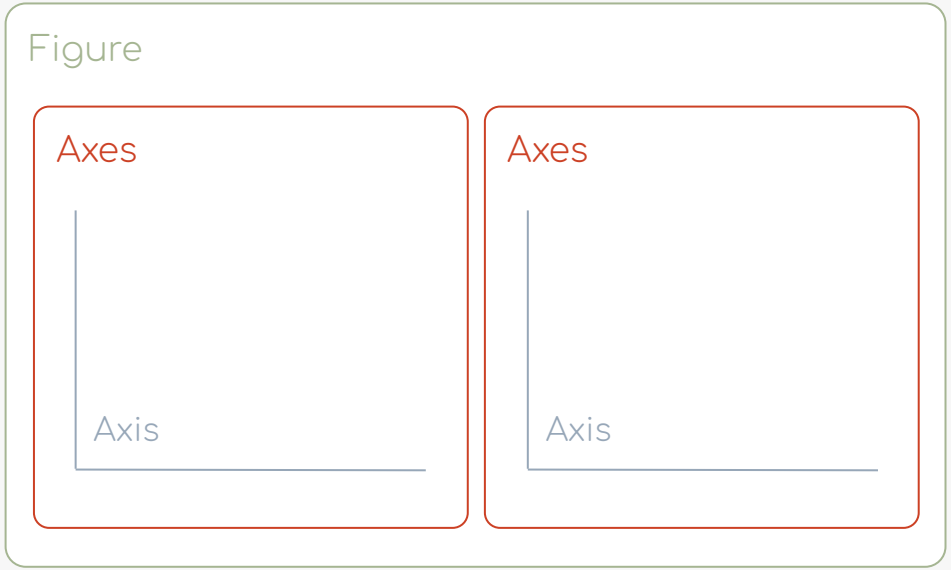

Graphiques en Python - Matplotlib

- Matplotlib

  Composants d'une Figure `matplotlib`.

  source : documentation officielle

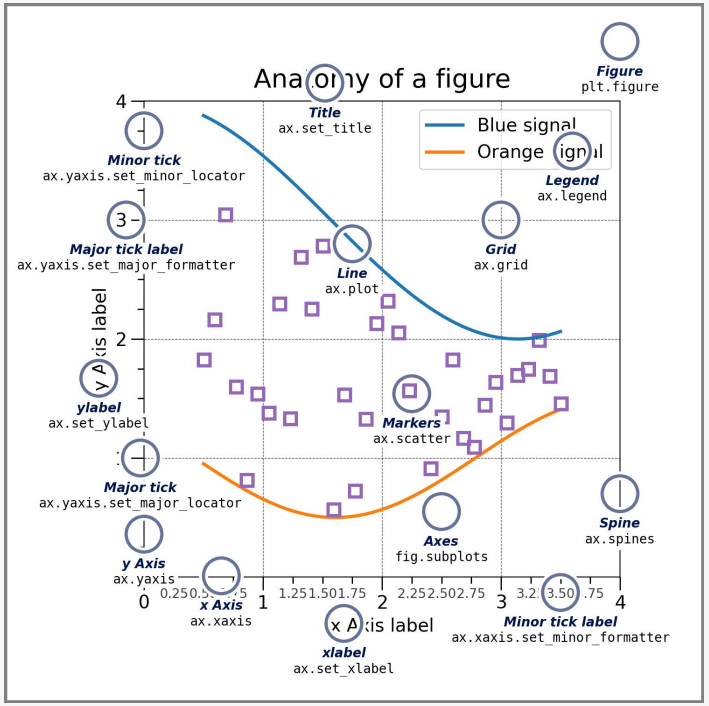

Graphiques en Python - Seaborn

- Seaborn
  - Package Python construit à partir de `matplotlib`
  - Simplifie la construction de graphiques pour les DataFrame

Graphiques en Python - Exemples

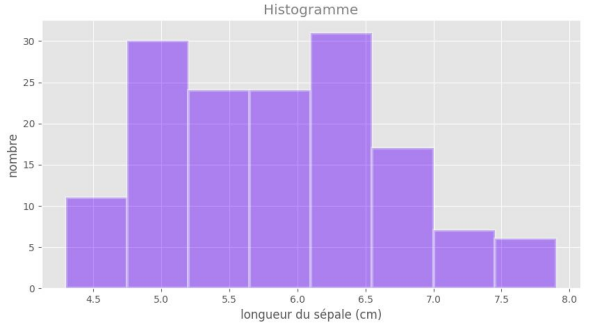

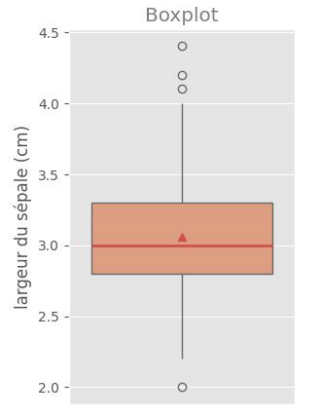

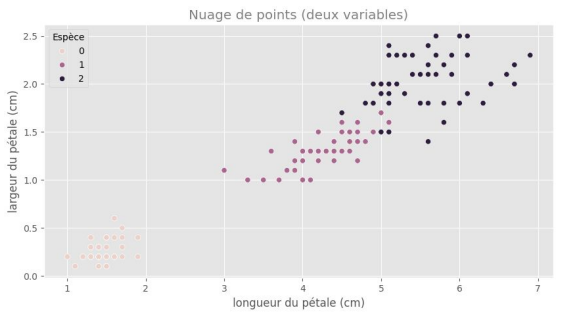

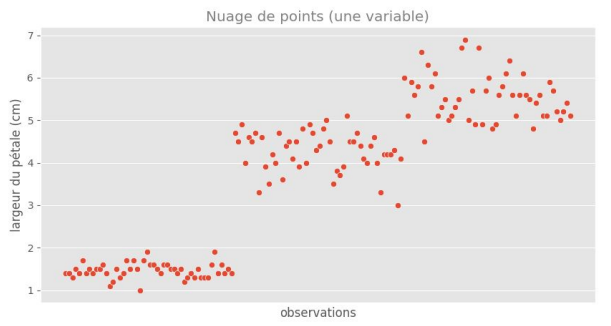

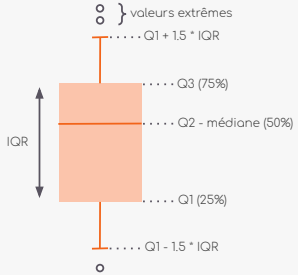

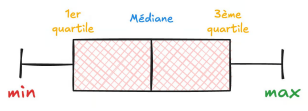

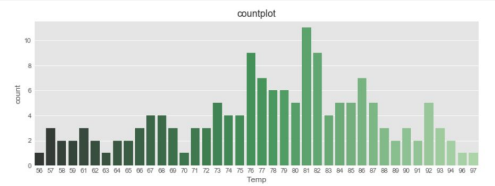

Pairplot (seaborn)

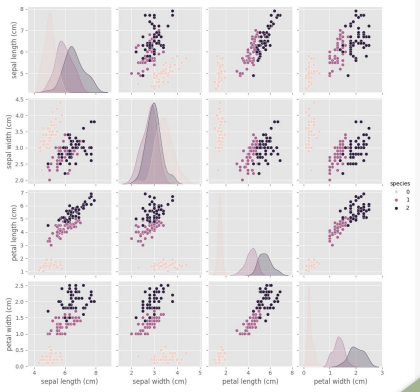

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  Exemple : âge et date de naissance, localisation et pays, âge et retraite

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante

  Exemple : âge et date de naissance, localisation et pays, âge et retraite

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante

```
# Filtre logique
```

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante

```
# Reconstitution de la variable pour comparaison
df["variable_reconstituée"] = ...
# Filtre logique pour identifier les incohérences
df[df["variable_reconstituée"] != df["variable_originale"]]
```

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement

```
df.dtypes
```

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : ?

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : PIB

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : PIB
  - **discrète** : ensemble fini de valeurs isolées ou infini discret (ex : entiers naturels)
    Exemple : ?

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : PIB
  - **discrète** : ensemble fini de valeurs ou infini discret (ex : entiers naturels)
    Exemple : nombre d'enfants

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : PIB
  - **discrète** : ensemble fini de valeurs ou infini discret (ex : entiers naturels)
    Exemple : nombre d'enfants
- **qualitative (ou catégorique)** : caractéristique non quantifiable qui ne peut prendre qu'un ensemble fini de valeurs, appelées modalités, **textuelles ou numériques**

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : PIB
  - **discrète** : ensemble fini de valeurs ou infini discret (ex : entiers naturels)
    Exemple : nombre d'enfants
- **qualitative (ou catégorique)** : caractéristique non quantifiable qui ne peut prendre qu'un ensemble fini de valeurs, appelées modalités, textuelles ou numériques
  - **ordinale** : s'il existe un relation d'ordre entre les valeurs
    Exemple : ?

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : PIB
  - **discrète** : ensemble fini de valeurs ou infini discret (ex : entiers naturels)
    Exemple : nombre d'enfants
- **qualitative (ou catégorique)** : caractéristique non quantifiable qui ne peut prendre qu'un ensemble fini de valeurs, appelées modalités, textuelles ou numériques
  - **ordinale** : s'il existe un relation d'ordre entre les valeurs
    Exemple : mentions au bac
  - **nominale** : sinon
    Exemple : ?

Explorer les données : Contenu - Catégories de variable

Rappel : Une variable peut être …

- **quantitative (ou numérique)** : caractéristique quantifiable
  - **continue** : ensemble continu de valeurs
    Exemple : PIB
  - **discrète** : ensemble fini de valeurs ou infini discret (ex : entiers naturels)
    Exemple : nombre d'enfants
- **qualitative (ou catégorique)** : caractéristique non quantifiable qui ne peut prendre qu'un ensemble fini de valeurs, appelées modalités, textuelles ou numériques
  - **ordinale** : s'il existe un relation d'ordre entre les valeurs
    Exemple : mentions au bac
  - **nominale** : sinon
    Exemple : modes de transport

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement
  - Est-ce que Pandas a correctement deviné le type des variables ?
    Exemple : chaînes de caractères de type `object` plutôt que `string`

fumeur / non fumeur ?

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement
  - Est-ce que Pandas a correctement deviné le type des variables ?
  - Quel est le choix optimal étant donné l'utilisation prévue ?

    Exemple : variables qualitatives non numériques et régression linéaire ; `int` plutôt que `string` pour des variables qualitatives nominales

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement
  - Est-ce que Pandas a correctement deviné le type des variables ?
  - Quel est le choix optimal étant donné l'utilisation prévue ?
- Y a-t-il des **observations ou** des **variables superflues** ? Adéquation à l'usage, Traitement

focus Grand-Est ?

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement
  - Est-ce que Pandas a correctement deviné le type des variables ?
  - Quel est le choix optimal étant donné l'utilisation prévue ?
- Y a-t-il des **observations ou** des **variables superflues** ? Adéquation à l'usage, Traitement
  Exemple : si focus région Grand-Est, les observations localisées ailleurs en France ne nous intéressent pas (lignes)

Explorer les données : Contenu

On connaît et on comprend désormais précisément ce que contient le jeu de données. On peut commencer à **préparer le traitement des données.**

- Quelles sont les **plages de valeurs attendues** pour chaque variable ? Traitement
  - Quelles **valeurs** pourraient être qualifiées d'**aberrantes ou** d'**atypique** ?
- Existe-t-il des **relations connues entre** certaines **variables** ? Traitement
  - Repérer des **incohérences internes**
  - Compléter d'éventuelles valeurs manquantes à l'étape suivante
- Quels **types** devraient avoir chaque variable ? Afficher les types. Adéquation à l'usage, Traitement
  - Est-ce que Pandas a correctement deviné le type des variables ?
  - Quel est le choix optimal étant donné l'utilisation prévue ?
- Y a-t-il des **observations ou** des **variables superflues** ? Adéquation à l'usage, Traitement
  Exemple : si focus secteur de l'agriculture et du tertiaire, les autres secteurs ne nous intéressent pas (colonnes)

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement

```
df.duplicated(subset=..., keep=...)
```

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement

  Exemple :
  - différentes abréviations ou casse pour les États des États-Unis (ex : `WI`, `Wi`, `Wis`, `Wisconsin`, `wisconsin` ...)

Pourquoi est-ce problématique d'après vous ?

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
  Exemple :
  - différentes abréviations ou casse pour les États des États-Unis (ex : `WI`, `Wi`, `Wis`, `Wisconsin`, `wisconsin` ...)
  - différents formats pour les coordonnées géographiques (ex : `(37.7749,-122.4194)` , `(37° 46.494' N, 122° 25.164' W)` ...)
  - différents formats pour les dates (ex : `01/07/2003`, `2004-12-02T23:00/2005-01-01T12:30` , `01.12.1997`, `2005-W52-1`, ...)

Exemples de problèmes connus lorsqu'on travaille avec des dates ou des localisations

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement

```
df[...].unique()
df[...].value_counts().sort_values(ascending=True)
# Il n'y a pas de commande magique, il faut se relever
les manches et fouiller les données
# Mais surtout : se renseigner
```

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement

```
df.isna()
```

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans **quelle proportion** ?

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans **quelle proportion** ?

```
df.isna().sum(axis=0).sort_values(ascending=False)
np.round(df.isna().mean(axis=0).sort_values(ascending=False) * 100, 2)
```

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle **aléatoire ou signifiante** ?

Explorer les données : Contenu - Valeurs manquantes

La classification de Rubin (1976) distingue 3 catégories de données manquantes, en fonction des causes sous-jacentes …

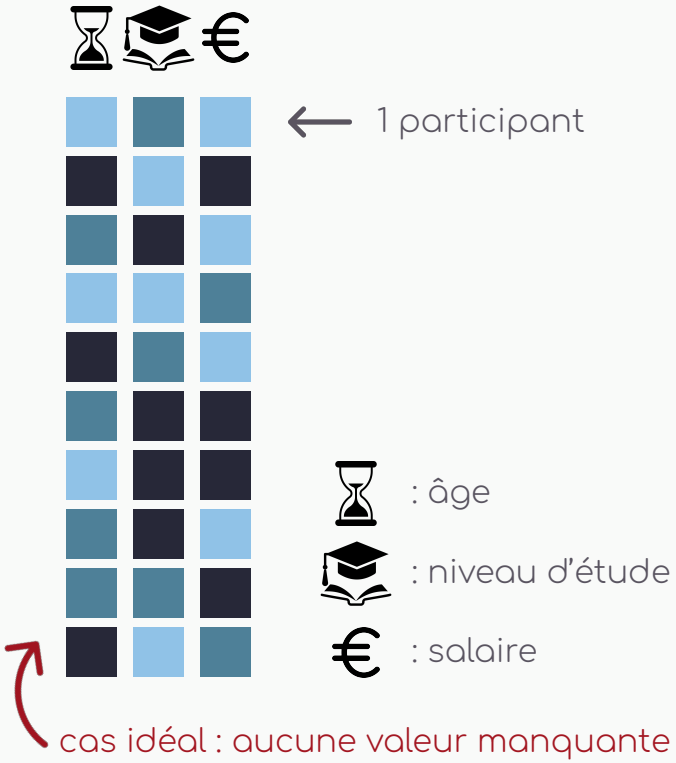

Nous souhaitons mener une enquête pour déterminer si le revenu des salariés dépend de leur niveau d'étude.

Les participant à l'enquête remplissent un questionnaire en ligne et renseignent :

- leur **âge**
- leur **niveau d'étude** (collège, lycée, licence, master, doctorat)
- leur **salaire annuel brut**

Pour simplifier :

- 1 couleur = 1 tranche d'âge
- 1 couleur = 1 niveau d'étude
- 1 couleur = 1 tranche de revenu

Après saisie, **des données manquantes sont observées** …

source : statinferentielle.fr

: âge

: niveau d'étude

: salaire

: données manquantes

MCAR

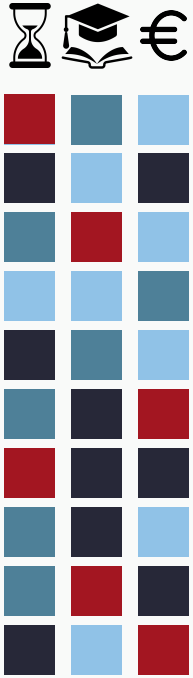

Premier cas

Un bug informatique a supprimé aléatoirement 20% des réponses du questionnaire !

source : statinferentielle.fr

: âge

: niveau d'étude

: salaire

: données manquantes

MCAR

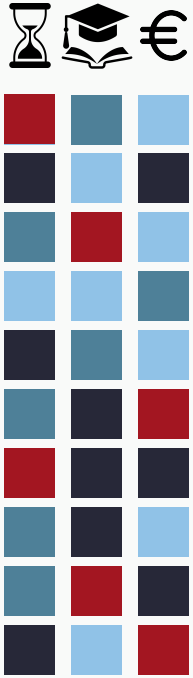

Premier cas

Un bug informatique a supprimé aléatoirement 20% des réponses du questionnaire !

Les entrées ont été supprimées **au hasard** : les valeurs manquantes ne concernent pas une catégorie de participants ou une variable en particulier.

source : statinferentielle.fr

Explorer les données : Contenu - Valeurs manquantes

On distingue 3 types de valeurs manquantes :

- MCAR (Missing Completely At Random)

  La **probabilité d'absence** est **identique** pour toutes les observations. L'absence est purement due au **hasard**.

  - L'absence ne dépend pas de la variable elle-même, i.e des valeurs qu'il aurait dû y avoir à la place des données manquantes
  - L'absence ne dépend pas des valeurs prises par une ou plusieurs autres variables observées
  - L'absence ne dépend pas de variables non observées

MAR

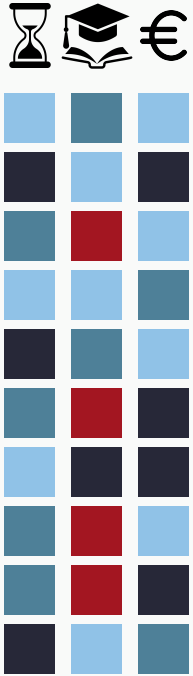

Deuxième cas

...

Quelle est la particularité de ces données manquantes ?

: âge

: niveau d'étude

: salaire

: données manquantes

source : statinferentielle.fr

MAR

Deuxième cas

...

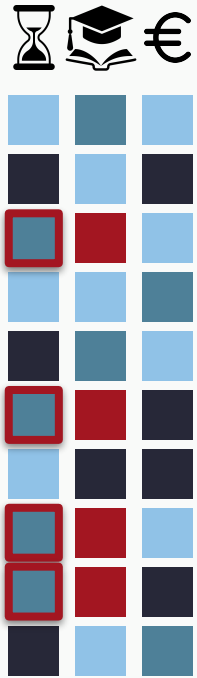

D'après vous, quelle pourrait en être la cause ?

: âge

: niveau d'étude

: salaire

: données manquantes

source : statinferentielle.fr

: âge

: niveau d'étude

: salaire

: données manquantes

MAR

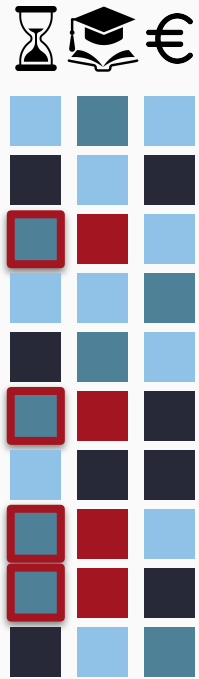

Deuxième cas

Les personnes âgées ont été moins enclines à répondre à la question concernant le niveau d'étude.

- Pour certains, les catégories ne correspondent pas au nom des diplômes à leur époque.
- Pour d'autres, ils ne se reconnaissent pas dans ces catégories car ils sont entrés dans l'emploi pas ou peu diplômés mais ont suivi des formations continues tout au long de leur carrière. Ils ne savent donc pas quoi répondre.

source : statinferentielle.fr

: âge

: niveau d'étude

: salaire

: données manquantes

MAR

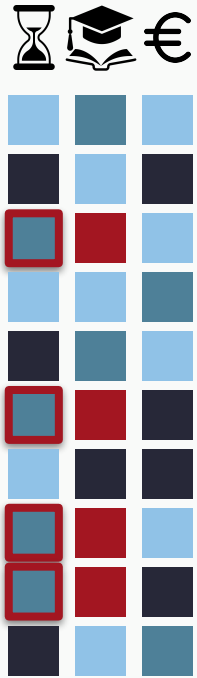

Deuxième cas

Les personnes âgées ont été moins enclines à répondre à la question concernant le niveau d'étude.

L'absence de réponse est **explicable par une autre variable observée** : l'âge.

Que se passerait-il si on se contentait de supprimer les lignes contenant des valeurs manquantes ?

source : statinferentielle.fr

Explorer les données : Contenu - Valeurs manquantes

On distingue 3 types de valeurs manquantes :

- MCAR (Missing Completely At Random)

  La **probabilité d'absence** est **identique** pour toutes les observations. L'absence est purement due au **hasard**.

- MAR (Missing At Random)

  La **probabilité d'absence** dépend d'une ou plusieurs **variables observées**, mais elle ne dépend ni de la variable d'intérêt, ni de variables non observées.

  - L'absence ne dépend pas de la variable elle-même, i.e des valeurs qu'il aurait dû y avoir à la place des données manquantes
  - L'absence dépend des valeurs prises par une ou plusieurs autres variables observées
  - L'absence ne dépend pas de variables non observées

MNAR

Troisième cas

...

Quelle est la particularité de ces données manquantes ?

: âge

: niveau d'étude

: salaire

: données manquantes

source : statinferentielle.fr

MNAR

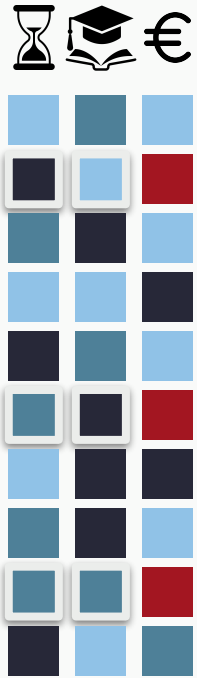

Troisième cas

...

Quelle est la particularité de ces données manquantes ?

: âge

: niveau d'étude

: salaire

: données manquantes

source : statinferentielle.fr

MNAR

Troisième cas

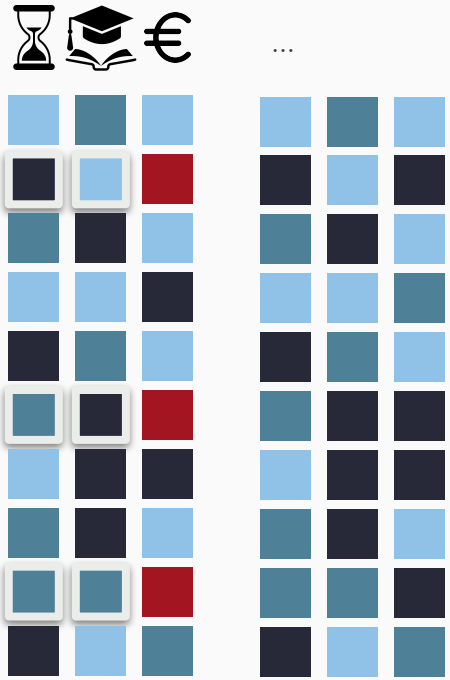

Un indice ...

: âge

: niveau d'étude

: salaire

: données manquantes

cas idéal : aucune valeur manquante

source : statinferentielle.fr

MNAR

Troisième cas

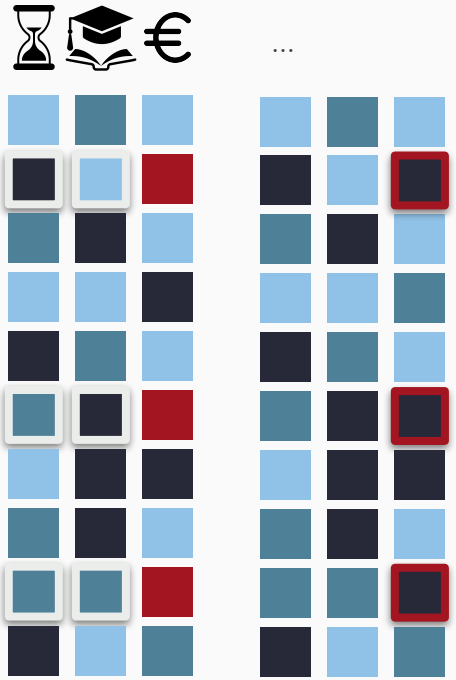

Quelle pourrait en être la cause ?

: âge

: niveau d'étude

: salaire

: données manquantes

cas idéal : aucune valeur manquante

source : statinferentielle.fr

MNAR

Troisième cas

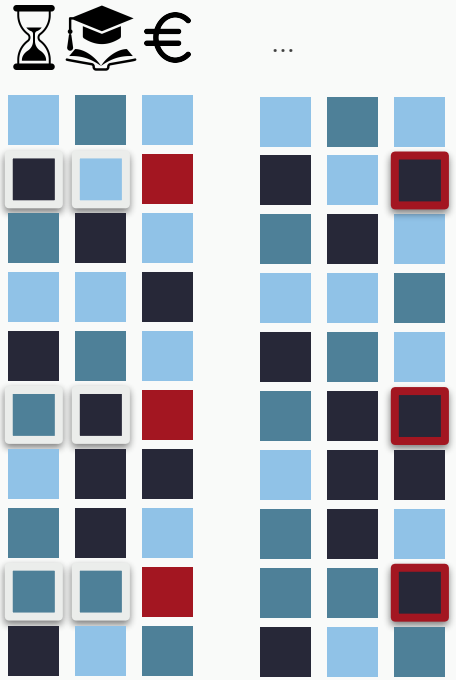

...

En tant normal, nous n'avons pas accès à ces informations ...

: âge

: niveau d'étude

: salaire

: données manquantes

cas idéal : aucune valeur manquante

source : statinferentielle.fr

: âge

: niveau d'étude

: salaire

: données manquantes

MNAR

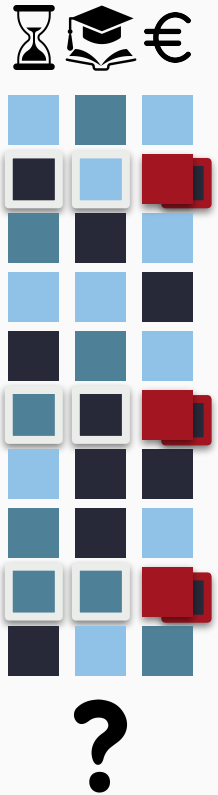

Troisième cas

Les participants aux revenus les plus élevés ont été moins enclins à répondre à la question sur le salaire, probablement par gêne ou par souci de confidentialité.

Aucune des autres **variables observées** ne peut expliquer l'absence de réponse pour le salaire, car c'est la **valeur en elle-même** – le salaire élevé – qui motive la non-réponse.

source : statinferentielle.fr

: âge

: niveau d'étude

: salaire

: données manquantes

MNAR

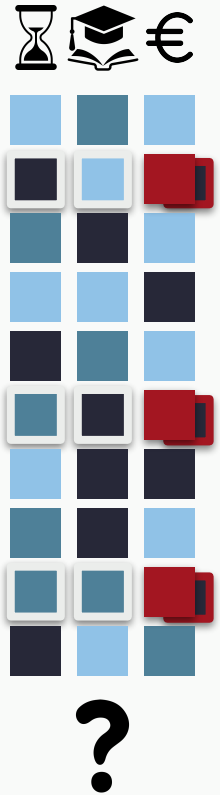

Troisième cas

Les participants aux revenus les plus élevés ont été moins enclins à répondre à la question sur le salaire, probablement par gêne ou par souci de confidentialité.

Aucune des autres **variables observées** ne peut expliquer l'absence de réponse pour le salaire, car c'est la **valeur en elle-même** – le salaire élevé – qui motive la non-réponse.

Que se passerait-il si on se contentait de supprimer les lignes contenant des valeurs manquantes ?

source : statinferentielle.fr

Explorer les données : Contenu - Valeurs manquantes

On distingue 3 types de valeurs manquantes :

- MCAR (Missing Completely At Random)

  La **probabilité d'absence** est **identique** pour toutes les observations. L'absence est purement due au **hasard**.

- MAR (Missing At Random)

  La **probabilité d'absence** dépend d'une ou plusieurs **variables observées**, mais elle ne dépend ni de la variable d'intérêt, ni de variables non observées.

- MNAR (Missing Not At Random)

  La **probabilité d'absence** dépend de la **variable d'intérêt** ou de **variables non observées.**

  - L'absence dépend de la variable elle-même, i.e des valeurs qu'il aurait dû y avoir à la place des données manquantes
  - L'absence ne dépend pas (ou pas entièrement) des valeurs prises par une ou plusieurs autres variables observées
  - L'absence dépend de variables non observées

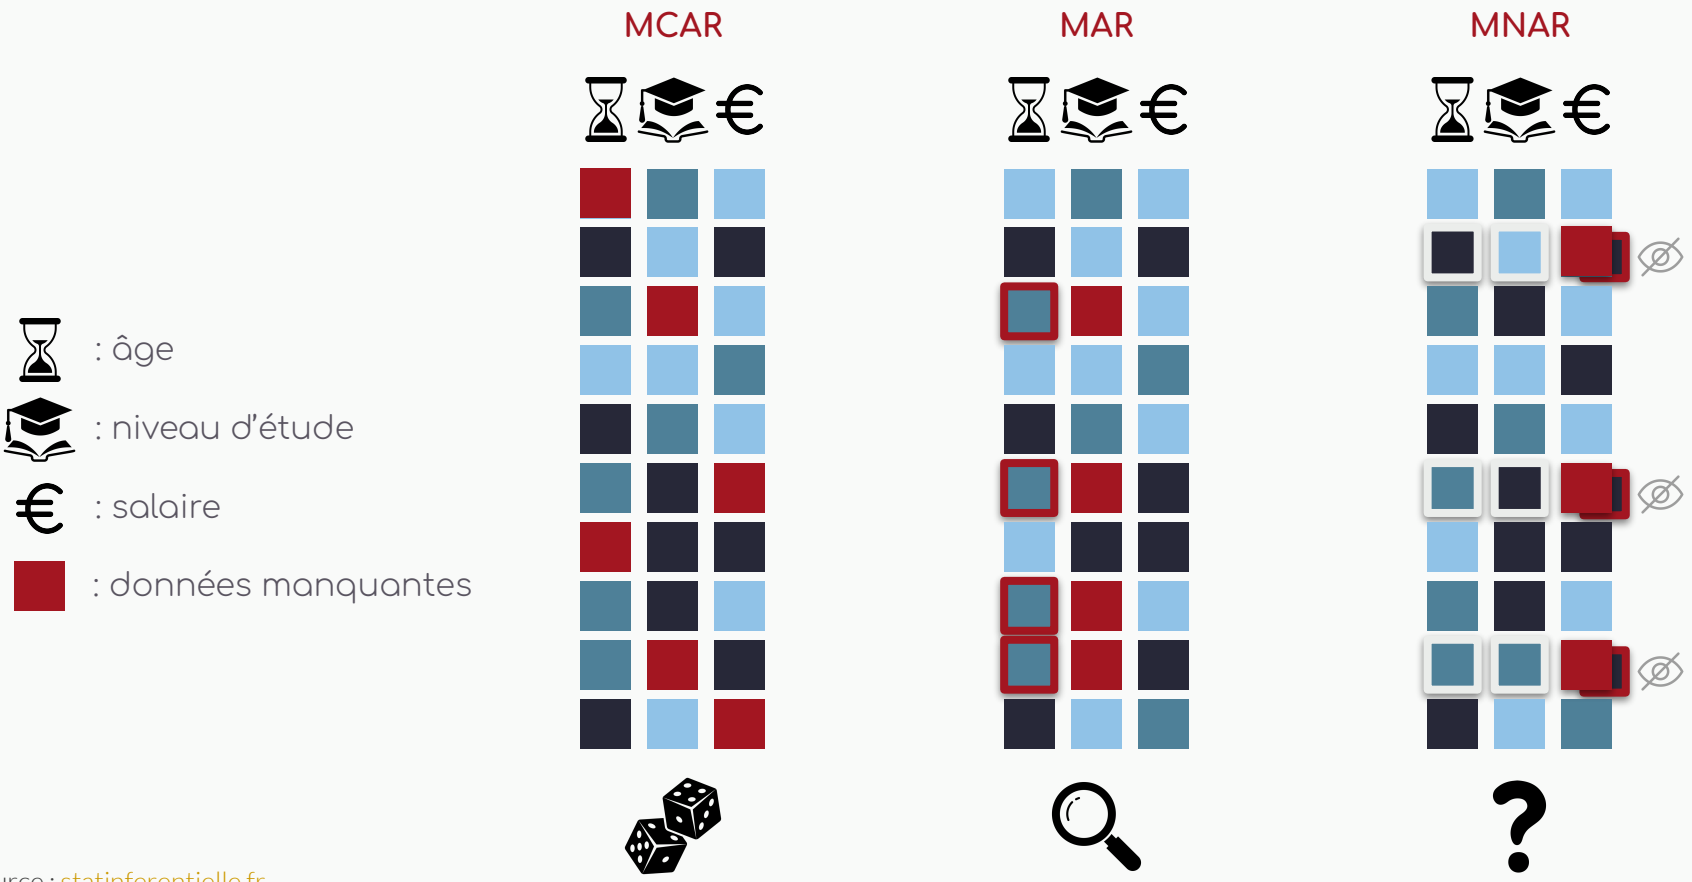

source : statinferentielle.fr

Explorer les données : Contenu - Valeurs manquantes

On distingue 3 types de valeurs manquantes :

- MCAR (Missing Completely At Random)

  La **probabilité d'absence** est **identique** pour toutes les observations. L'absence est purement due au **hasard**.

- MAR (Missing At Random)

  La **probabilité d'absence** dépend d'une ou plusieurs **variables observées**, mais elle ne dépend ni de la variable d'intérêt, ni de variables non observées.

- MNAR (Missing Not At Random)

  La **probabilité d'absence** dépend de la **variable d'intérêt** ou de **variables non observées.**

Explorer les données : Contenu - Valeurs manquantes

On distingue 3 types de valeurs manquantes :

- MCAR (Missing Completely At Random)

  La **probabilité d'absence** est **identique** pour toutes les observations. L'absence est purement due au **hasard**.

- MAR (Missing At Random)

  La **probabilité d'absence** dépend d'une ou plusieurs **variables observées**, mais elle ne dépend ni de la variable d'intérêt, ni de variables non observées.

- MNAR (Missing Not At Random)

  La **probabilité d'absence** dépend de la **variable d'intérêt** ou de **variables non observées.**

- **Identifier la cause** des valeurs manquantes (et donc la catégorie à laquelle elles appartiennent) peut s'avérer **difficile**. Souvent, cela nécessite de **combiner analyses exploratoires et connaissances métier**.

Explorer les données : Contenu - Valeurs manquantes

Quelques pistes pour déterminer le type des données manquantes :

- **MCAR :** Vérifiez s'il y a des **motifs apparents** dans les données manquantes
  - Les données sont-elles réparties uniformément au hasard ou sont-elles concentrées chez certains individus ou variables ?

Explorer les données : Contenu - Valeurs manquantes

Quelques pistes pour déterminer le type des données manquantes :

- MCAR : Vérifiez s'il y a des **motifs apparents** dans les données manquantes
- MAR : Vérifiez si la **présence de données manquantes** est **explicable** par une ou plusieurs variables observées
  - Existe-t-il une **corrélation** entre la présence de données manquantes pour une variable donnée et les valeurs d'une ou plusieurs autres variables observées ?
    - Les données manquantes sont-elles **plus fréquentes** chez un certains groupe d'âge, dans certaines zones géographiques, pour l'un des deux sexes, etc. ?
    - Existe-t-il des **différences significatives** entre les groupes identifiés comme contenant des valeurs manquantes et le reste des données ?
    - etc.

Explorer les données : Contenu - Valeurs manquantes

Quelques pistes pour déterminer le type des données manquantes :

- **MCAR :** Vérifiez s'il y a des **motifs apparents** dans les données manquantes
- **MAR :** Vérifiez si la **présence de données manquantes** est **explicable** par une ou plusieurs variables observées
- **MNAR :** Renseignez-vous sur le **contexte**
  - Est-il **plausible** que l'absence de valeur pour une variable donnée soit due à la valeur elle-même ?
    exemple : pour des sujets sensibles (revenu, addictions, santé, sexualité, opinions, secret défense …), les "mauvaises" valeurs (très élevées, très basses, socialement ou politiquement délicates, chargées émotionnellement …) pourraient être plus fréquemment absentes

Explorer les données : Contenu - Valeurs manquantes

Quelques pistes pour déterminer le type des données manquantes :

- **MCAR :** Vérifiez s'il y a des **motifs apparents** dans les données manquantes
- **MAR :** Vérifiez si la **présence de données manquantes** est **explicable** par une ou plusieurs variables observées
- **MNAR :** Renseignez-vous sur le **contexte**
  - Est-il **plausible** que l'absence de valeur pour une variable donnée soit due à la valeur elle-même ?
    exemple : pour des sujets sensibles (revenu, addictions, santé, sexualité, opinions, secret défense …), les "mauvaises" valeurs (très élevées, très basses, socialement ou politiquement délicates, chargées émotionnellement …) pourraient être plus fréquemment absentes
  - Existe-t-il des **problématiques connues** concernant les données sur lesquelles vous travaillez ? (MAR, MNAR)
    exemple : localisation et espèces braconnées, données personnelles et RGPD, données statistiques et pays précaires ou autoritaires

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?

```
Boîte à moustache (boxplot)
```

```
# Détecter MAR
df.loc[pd.isna(df[...]), ...].mean()
df.loc[~pd.isna(df[...]), ...].mean()
```

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?
- Y a-t-il des **biais** dans les données ? Des déséquilibres ? Adéquation à l'usage, Traitement
  Exemple : beaucoup plus de données dans tel département ; grande variation du nombre d'observations d'une année à l'autre

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?
- Y a-t-il des **biais** dans les données ? Des déséquilibres ? Adéquation à l'usage, Traitement

Une dimension :

Histogramme (histogram)

Count plot

Density Plot

Deux dimensions :

Heatmap

Hexbin

Carte

```
df[...].value_counts()
```

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?
- Y a-t-il des **biais** dans les données ? Des déséquilibres ? Adéquation à l'usage, Traitement
- Les données sont-elles suffisantes seules ou faut-il les **enrichir** étant donné l'utilisation envisagée ? Traitement

  La véritable valeur réside dans la combinaison de plusieurs sources de données

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?
- Y a-t-il des **biais** dans les données ? Des déséquilibres ? Adéquation à l'usage, Traitement
- Les données sont-elles suffisantes seules ou faut-il les **enrichir** étant donné l'utilisation envisagée ? Traitement

  Exemple :

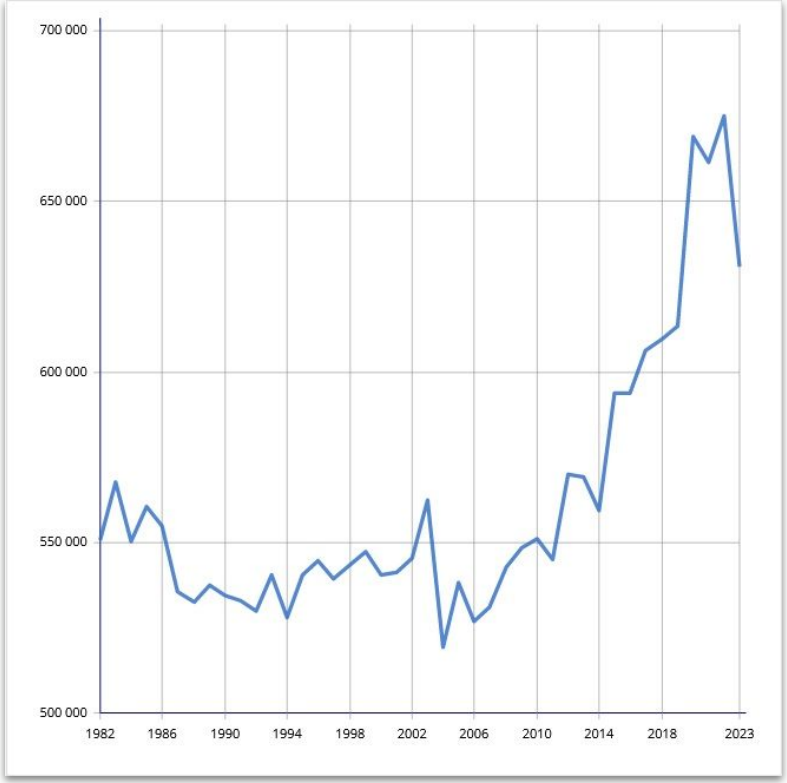

Historique du **nombre de décès** en France entre 1982 et 2023, Insee

Que se passe-t-il en France ??

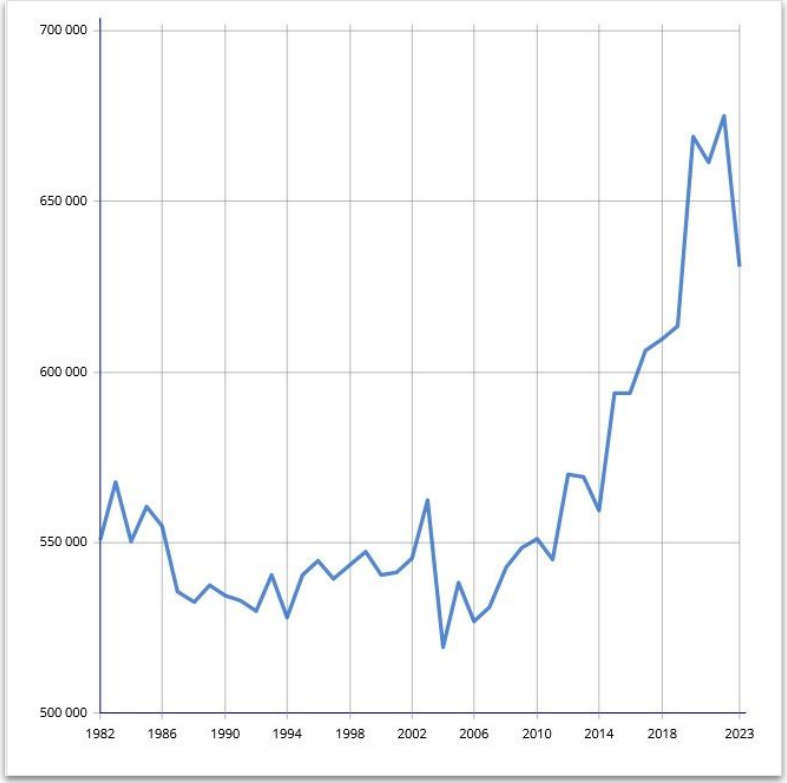

Historique du **nombre de décès** en France entre 1982 et 2023, Insee

Enrichir les données par :

- Évolution de la population totale en France

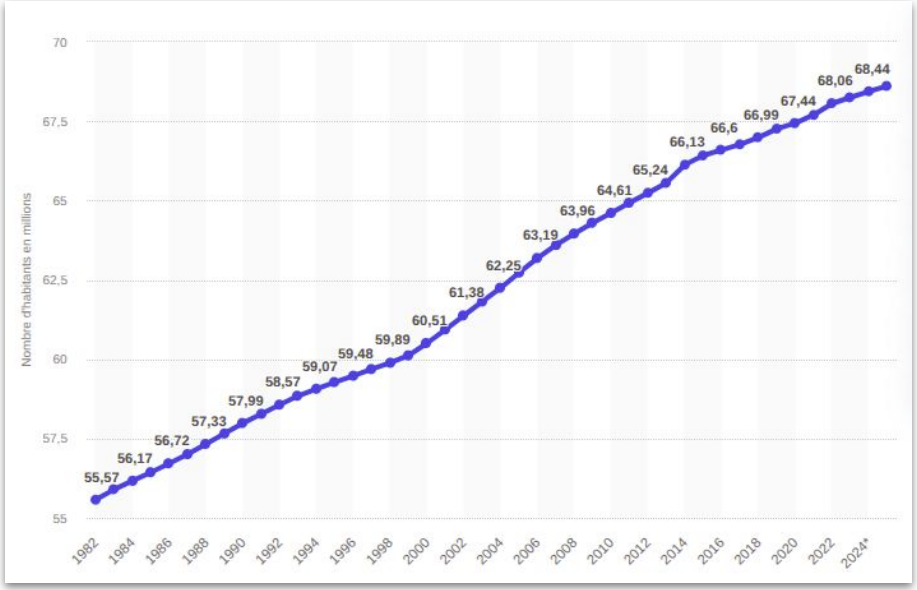

Évolution du **nombre d'habitants** en France entre 1982 et 2024, Insee

Année	Nombre de décès	Taux de mortalité (pour 1 000 habitants)
2024 (p)	646 000	9,4
2023 (p)	639 269	9,4
2022 (p)	675 122	9,9
2021	661 585	9,7
2020	668 922	9,9
2019	613 243	9,1
2018	609 648	9,1
2017	606 274	9,1
2016	593 865	8,9
2015	593 680	8,9
2014 y c. Mayotte	559 293	8,4
2014 hors Mayotte	558 727	8,5

Historique du **taux de mortalité** en France entre 2014 et 2023, Insee

Enrichir les données par :

- Évolution de la population totale en France

Année	Nombre de décès	Taux de mortalité (pour 1 000 habitants)
2024 (p)	646 000	9,4
2023 (p)	639 269	9,4
2022 (p)	675 122	9,9
2021	661 585	9,7
2020	668 922	9,9
2019	613 243	9,1
2018	609 648	9,1
2017	606 274	9,1
2016	593 865	8,9
2015	593 680	8,9
2014 y c. Mayotte	559 293	8,4
2014 hors Mayotte	558 727	8,5

Historique du **taux de mortalité** en France entre 2014 et 2023, Insee

Enrichir les données par :

- Évolution de la population totale en France
- Vieillissement de la population

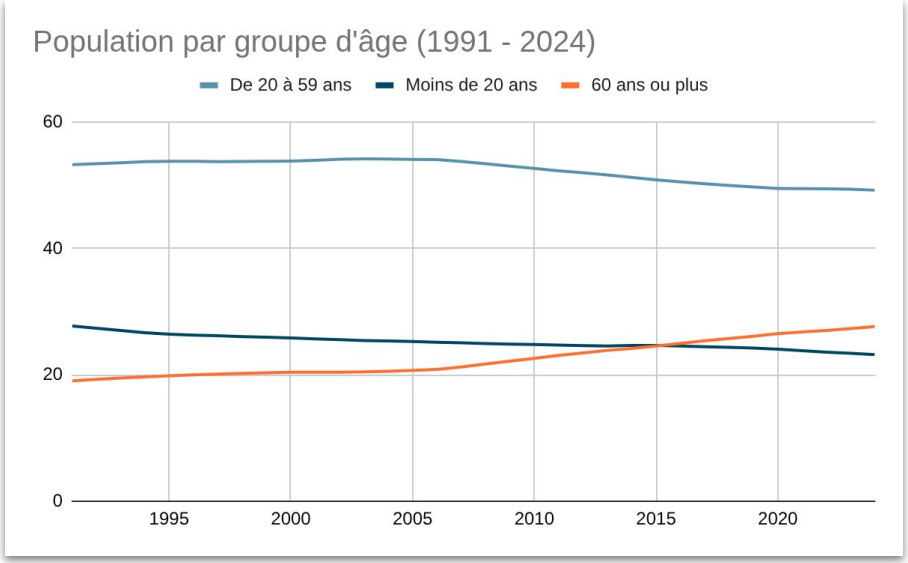

Année	Nombre de décès	Taux de mortalité (pour 1 000 habitants)
2024 (p)	646 000	9,4
2023 (p)		
2022 (p)		
2021		
2020		
2019		
2018		
2017		
2016		
2015		
2014 y		
2014 ho		

Histor
2023,

Enrichir les données par :

- Évolution de la population totale en France
- Vieillissement de la population
- Autre : épidémie de grippe, épidémie de Covid-19 …

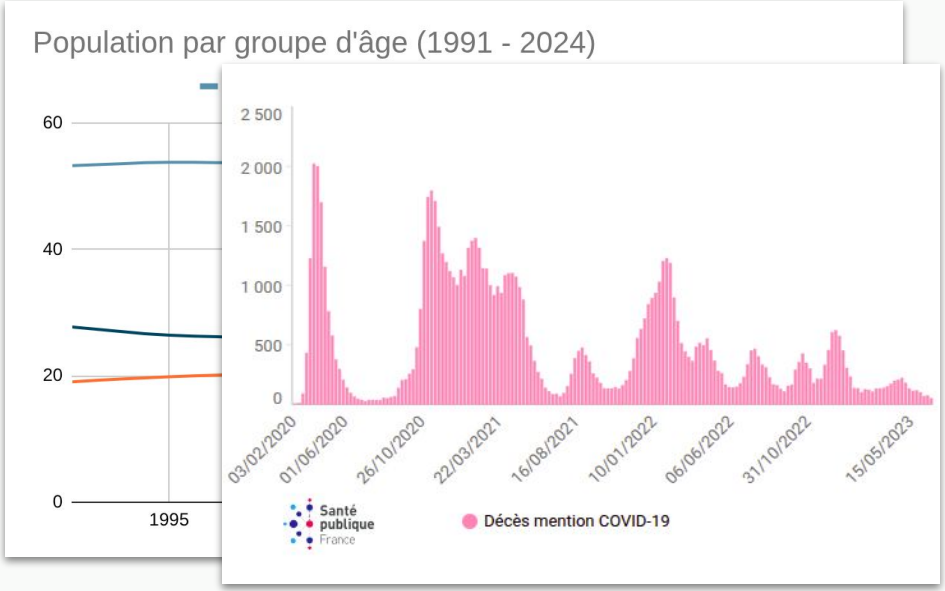

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?
- Y a-t-il des **biais** dans les données ? Des déséquilibres ? Adéquation à l'usage, Traitement
- Les données sont-elles suffisantes seules ou faut-il les **enrichir** étant donné l'utilisation envisagée ? Traitement

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?
- Y a-t-il des **biais** dans les données ? Des déséquilibres ? Adéquation à l'usage, Traitement
- Les données sont-elles suffisantes seules ou faut-il les **enrichir** étant donné l'utilisation envisagée ? Traitement

```
# Enrichir un jeu de données
pd.concat()
pd.merge()
```

Explorer les données : Contenu

- Y a-t-il des **doublons** dans les données (données dupliquées) ? Traitement
- Existe-t-il des **disparités de format** parmi les **valeurs** d'une même colonne ? Traitement
- Y a-t-il des **valeurs manquantes** dans le jeu de données ? Adéquation à l'usage, Traitement
  - Si oui, combien ou dans quelle proportion ?
  - L'absence de valeurs est-elle aléatoire ou signifiante ?
  - Concerne-t-elle des variables importantes au vu de l'utilisation que l'on compte faire des données ?
- Y a-t-il des **biais** dans les données ? Des déséquilibres ? Adéquation à l'usage, Traitement
- Les données sont-elles suffisantes seules ou faut-il les **enrichir** étant donné l'utilisation envisagée ? Traitement
- Y a-t-il d'autres problèmes spécifiques à nos données ? Traitement
  Exemple : coordonnées géographiques utilisant différents systèmes de projections ; heures et décalage horaire ou heure et changement d'heures

Explorer les données : Structure

- Format wide vs. long : Adéquation à l'usage, Traitement
  - **Format wide** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **colonnes différentes**
  - **Format long** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **lignes différentes** avec une colonne permettant de distinguer les niveaux d'observations

Explorer les données : Structure

- Format wide vs. long : Adéquation à l'usage, Traitement
  - **Format wide** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **colonnes différentes**
  - **Format long** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **lignes différentes** avec une colonne permettant de distinguer les niveaux d'observations

Exemple :

pays	PIB_1998	PIB_2010
États-Unis	7 394 598	14 624 184
Chine	3 873 352	10 084 369
France	1 150 080	2 146 283

wide

long

pays	annee	PIB
États-Unis	1998	7 394 598
États-Unis	2010	14 624 184
Chine	1998	3 873 352
Chine	2010	10 084 369
France	1998	1 150 080
France	2010	2 146 283

Explorer les données : Structure

- Format wide vs. long : Adéquation à l'usage, Traitement
  - **Format wide** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **colonnes différentes**
  - **Format long** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **lignes différentes** avec une colonne permettant de distinguer les niveaux d'observations

Exemple :

pays	PIB_1998	PIB_2010
États-Unis	7 394 598	14 624 184
Chine	3 873 352	10 084 369
France	1 150 080	2 146 283

wide

long

pays	annee	PIB
États-Unis	1998	7 394 598
États-Unis	2010	14 624 184
Chine	1998	3 873 352
Chine	2010	10 084 369
France	1998	1 150 080
France	2010	2 146 283

Explorer les données : Structure

- Format wide vs. long : Adéquation à l'usage, Traitement
  - **Format wide** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **colonnes différentes**
  - **Format long** : les données comportent des observations répétées pour un même individu (ou groupe) dans des **lignes différentes** avec une colonne permettant de distinguer les niveaux d'observations

Quel est le format de nos données ?

Explorer les données : Structure

- Format wide vs. long Adéquation à l'usage, Traitement

Explorer les données : Structure

- Format wide vs. long Adéquation à l'usage, Traitement
- Niveau d'agrégat Adéquation à l'usage, Traitement

  Rappel : Quand ? Où ?

Explorer les données : Structure

- Format wide vs. long Adéquation à l'usage, Traitement
- Niveau d'agrégat Adéquation à l'usage, Traitement
  - Quel est le niveau de détail ou l'échelle souhaitée ?
    Exemple : étude au niveau départemental plutôt que communal (nécessité d'agréger)

Explorer les données : Structure

- Format wide vs. long Adéquation à l'usage, Traitement
- Niveau d'agrégat Adéquation à l'usage, Traitement
  - Quel est le niveau de détail ou l'échelle souhaitée ?
    Exemple : étude au niveau départemental plutôt que communal (nécessité d'agréger)
  - Quel est le choix optimal étant donné l'utilisation prévue ?
    Exemple : plusieurs variables binaires plutôt qu'une seule variable qualitative selon les modèles envisagés (nécessité de décomposer)

Explorer les données : Structure

- Format wide vs. long Adéquation à l'usage, Traitement
- Niveau d'agrégat Adéquation à l'usage, Traitement
  - Quel est le niveau de détail ou l'échelle souhaitée ?
    Exemple : étude au niveau départemental plutôt que communal (nécessité d'agréger)
  - Quel est le choix optimal étant donné l'utilisation prévue ?
    Exemple : plusieurs variables binaires plutôt qu'une seule variable qualitative selon les modèles envisagés (nécessité de décomposer)
- Labels des lignes et des colonnes Traitement

Les noms des colonnes sont-ils bien choisis ?

Explorer les données : Structure

- Format wide vs. long Adéquation à l'usage, Traitement
- Niveau d'agrégat Adéquation à l'usage, Traitement
  - Quel est le niveau de détail ou l'échelle souhaitée ?
    Exemple : étude au niveau départemental plutôt que communal (nécessité d'agréger)
  - Quel est le choix optimal étant donné l'utilisation prévue ?
    Exemple : plusieurs variables binaires plutôt qu'une seule variable qualitative selon les modèles envisagés (nécessité de décomposer)
- Labels des lignes et des colonnes Traitement

  Rappel : évitez les espaces, les caractères spéciaux (dont accents), tout en minuscule avec underscore ou syntaxe camelCase …

Comprendre & Explorer les données

Cette étape permet de répondre aux questions suivantes :

- Sur quoi porte le jeu de données ?
- Les données sont-elles adaptées à l'utilisation que je souhaite en faire ?
    - Les données sont-elles à la bonne échelle, spatiale et temporelle ?
    - Les données doivent-elles être nettoyées au préalable ? (qualité des données)
    - Faut-il enrichir le jeu de données avec des données provenant d'autres sources ?

Comprendre & Explorer les données

Concernant la qualité des données, les problématiques suivantes ont été abordées :

- valeurs aberrantes ou atypiques
- incohérence interne
- catégorie des variables et type
- observations ou variables superflues
- données dupliquées
- format que peuvent prendre les valeurs d'une variable
- données manquantes
- niveau d'agrégation des données
- problématiques spécifiques aux données
- biais dans le jeu de données
- exhaustivité du jeu de données
- format du jeu de données (structure wide / long, labels des lignes et des colonnes)

Plan

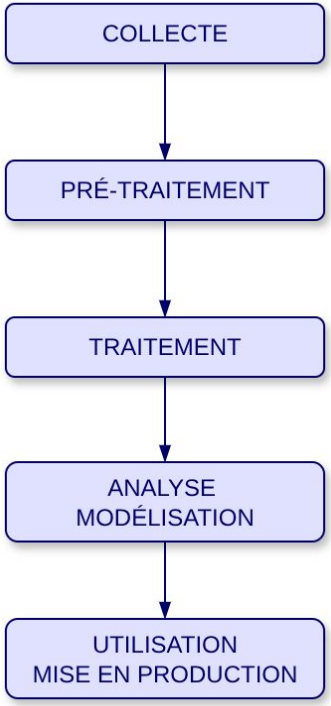

1. Collecter les données
2. Comprendre les données
3. Explorer les données
4. Traiter les données
5. Exploiter les données
6. Agir grâce aux données

MERCI